UNIVERSITAS GUNADARMA

FAKULTAS ILMU KOMPUTER & TEKNOLOGI INFORMASI

IMPLEMENTASI METODE *CONVOLUTIONAL NEURAL NETWORK* (CNN) UNTUK KLASIFIKASI TUMBUHAN DIKOTIL DAN MONOKOTIL BERDASARKAN CITRA BENTUK DAUN

Disusun Oleh:

Nama	**: Farhan Putra Bunga Mayang**
NPM	**: 10121442**
Program Studi	**: Sistem Informasi**
Pembimbing	**: Dr. Fenni Agustina, SKom., MMSI., M.I.Kom.**

Diajukan Guna Melengkapi Sebagaian Syarat
Dalam Mencapai Gelar Sarjana Strata Satu (S1)

JAKARTA

2025

PERNYATAAN ORIGINALITAS DAN PUBLIKASI

Saya yang bertanda tangan dibawah ini,

Nama Mahasiswa	: Farhan Putra Bunga Mayang
NPM	: 10121442
Judul Skripsi	: Implentasi Metode *Convolutional Neural Network (CNN)* Untuk Klasifikasi Tumbuhan Dikotil Dan Monokotil Berdasarkan Citra Bentuk Daun.
Tanggal Sidang	: 2 September 2025
Tanggal Lulus	: 2 September 2025

Menyatakan bahwa tulisan ini adalah merupakan hasil karya saya sendiri dan dapat dipublikasikan sepenuhnya oleh Universitas Gunadarma. Segala kutipan dalam bentuk apa pun telah mengikuti kaidah, etika yang berlaku. Mengenai isi dan tulisan adalah merupakan tanggung jawab Penulis, bukan Universitas Gunadarma. Demikian pernyataan ini dibuat dengan sebenarnya dan dengan penuh kesadaran.

Depok,11 Agustus 2025.

(Farhan Putra Bunga Mayang)

LEMBAR PENGESAHAN

Judul Skripsi : IMPLEMENTASI METODE *CONVOLUTIONAL NEURAL NETWORK (*CNN*)* UNTUK KLASIFIKASI TUMBUHAN DIKOTIL DAN MONOKOTIL BERDASARKAN CITRA BENTUK DAUN

Nama Mahasiswa : Farhan Putra Bunga Mayang

NPM : 10121442

Tanggal Lulus : 2 September 2025

PANITIA UJIAN

NO	NAMA	KEDUDUKAN
1	Dr. Ravi Ahmad Salim, SSi.	Ketua
2	Prof. Dr. Wahyudi Priyono	Sekretaris
3	Dr. Fenni Agustina, SKom., MMSI.	Anggota
4	Dr. Yuli Karyanti, SKom., MMSI.	Anggota
5	Dr. Tavipia Rumambi, SKom., MMSI.	Anggota

Menyetujui,

Pembimbing

Dr. Fenni Agustina, SKom., MMSI.

Bagian Sidang Ujian

Dr. Edi Sukirman, S.Si., MM., M.I.Kom.

ABSTRAK

Farhan Putra Bunga Mayang, 10121442
Implementasi Metode *Convolutional Neural Network (CNN)* Untuk Klasifikasi Tumbuhan Dikotil Dan Monokotil Berdasarkan Citra Bentuk Daun.
Skripsi, Jurusan Sistem Informasi, Fakultas Ilmu Komputer dan Teknologi Informasi, Univeristas Gunadarma, 2025.
Kata Kunci*: Convolutional Neural Network*, *CNN*, *MobileNetV2*, Klasifikasi Citra, Daun Dikotil, Daun Monokotil, *Deep Learning*.

(xiv + 74 + Lampiran)

Tumbuhan dikotil dan monokotil memiliki ciri morfologi yang khas, terutama pada bentuk daun. Namun, identifikasi manual seringkali memakan waktu dan memerlukan keahlian khusus. Penelitian ini bertujuan untuk mengimplementasikan metode *Convolutional Neural Network* (CNN) dengan arsitektur *MobileNetV2* untuk membuat sistem klasifikasi otomatis antara daun dikotil dan monokotil. *Dataset* yang digunakan terdiri dari 1201 citra daun yang diperoleh dari Kaggle, yang kemudian diaugmentasi untuk memperkaya data latih. Proses *preprocessing* dan augmentasi data dilakukan menggunakan *platform* Roboflow, dengan pembagian data 80% untuk pelatihan, 10% untuk validasi, dan 10% untuk pengujian. Model dilatih menggunakan teknik transfer *learning* pada *platform Google Colaboratory*. Hasil evaluasi pada data uji menunjukkan bahwa model yang dikembangkan mampu mencapai tingkat akurasi 98%, dengan nilai *precision*, *recall*, dan *F1-score* yang sempurna. Hasil ini membuktikan bahwa metode CNN dengan arsitektur *MobileNetV2* sangat efektif dan akurat untuk mengklasifikasikan tumbuhan dikotil dan monokotil berdasarkan citra bentuk daun.

Daftar Pustaka (2021-2025)

ABSTRACT

Farhan Putra Bunga Mayang, 10121442.
Implementation of the Convolutional Neural Network (CNN) Method for Classification of Dicotyledonous and Monocotyledonous Plants Based on Leaf Shape Images.
Undergraduate Thesis. Departement of Information System. Faculty of Computer Science and Information Technology, Gunadarma University, 2025.
Keywords: Convolutional Neural Network, CNN, MobileNetV2, Image Classification, Dicotyledonous Plants, Monocotyledonous Plants, Deep Learning.

*(*xiv + 74 + Attachment*)*

Dicot and monocot plants have distinctive morphological features, especially in the shape of their leaves. However, manual identification is often time-consuming and requires special expertise. This research aims to implement the Convolutional Neural Network (CNN) method with the MobileNetV2 architecture to create an automatic classification system for dicot and monocot leaves. The dataset used consists of 203 leaf images obtained from Kaggle, which were then augmented to enrich the training data. The data preprocessing and augmentation process was conducted using the Roboflow platform, with the data divided into 80% for training, 10% for validation, and 10% for testing. The model was trained using transfer learning techniques on the Google Colaboratory platform. Evaluation results on the test data show that the developed model achieved an accuracy level of 98%, with perfect precision, recall, and F1-score values. These results demonstrate that the CNN method with the MobileNetV2 architecture is highly effective and accurate for classifying dicot and monocot plants based on leaf shape imagery.

Bibliography (2021-2025).

KATA PENGANTAR

Segala puji dan syukur penulis panjatkan kepada Tuhan Yang Maha Esa yang telah memberikan berkat, anugerah, dan karunia yang melimpah, sehingga penulis dapat menyelesaikan Tugas Akhir ini.

Tugas akhir ini disusun guna melengkapi Sebagian syarat dalam mencapai gelar Setara Sarjana Satu pada jurusan Sistem Informasi, Fakultas Ilmu Komputer dan Teknologi Informasi, Universitas Gunadarma. Adapun judul skripsi ini adalah "Implementasi Metode *Convolutional Neural Network* (CNN) Untuk Klasifikasi Tumbuhan Dikotil Dan Monokotil Berdasarkan Citra Bentuk Daun".

Walaupun banyak kesulitan yang penulis harus hadapi ketika menyusun Penulisan Ilmiah ini, namun berkat bantuan dan dorongan dari berbagai pihak akhirnya tugas ini dapat diselesaikan dengan baik. Untuk itu penulis mengucapkan terima kasih, kepada:

1. Prof. Dr. E.S. Margianti, SE., MM., selaku Rektor Universitas Gunadarma.
2. Prof. Dr.rer-nat Achmad Benny Mutiara, selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Gunadarma.
3. Dr. Setia Wirawan, SKom., MMSI., selaku Ketua Program Studi Sistem Informasi Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Gunadarma.
4. Dr. Edi Sukirman, S.Si., MM., M.I.Kom., selaku Kepala Bagian Sidang Ujian Universitas Gunadarma.
5. Dr. Fenni Agustina, SKom., MMSI., M.I.Kom., selaku Dosen Pembimbing yang telah meluangkan waktu memberikan, membimbing dan arahan kepada penulis selama penulisan Tugas Akhir ini berlangsung hingga selesai.
6. Bapak dan Ibu Dosen Universitas Gunadarma yang telah memberikan banyak ilmu penghetahuan kepada penulis.

7. Kedua orang tua, yaitu Bapak H. Tamim dan Hj. Ibu Sari Endah Purwamti dan kedua kakak penulis, yaitu Fany Bunga Mayang dan Fara Bunga Mayang yang selalu mendukung, menyemangati, mendoakan dan memberikan bantuan baik moril maupun materil.
8. Teman-teman seperjuangan saat bimbingan, teman-teman kelas 4KA03 yang telah berjuang bersama dalam menyelesaikan studi di Universitas Gunadarma.
9. Teman – teman serta seluruh pihak yang tidak dapat disebutkan satu per satu yang telah mendukung dan membantu dalam proses Penulisan Ilmiah ini.

Penulis menyadari dalam penulisan tugas akhir ini banyak kekurangannya. Walaupun penulisan ini jauh dari sempurna, penulis berharap agar penulisan ini bermanfaat dan menambah wawasan bagi pihak-pihak yang membutuhkan. Akhir kata penulis mengharapkan kritik dan saran yang bersifat membangun untuk menjadi perbaikan di masa yang akan mendatang.

Depok,11 Agustus 2025.

Farhan Putra Bunga Mayang

DAFTAR ISI

PERNYATAAN ORIGINALITAS DAN PUBLIKASI ..... **ii**
LEMBAR PENGESAHAN ..... **iii**
ABSTRAK ..... **iv**
ABSTRACT ..... **v**
KATA PENGANTAR ..... **vi**
DAFTAR ISI ..... **viii**
DAFTAR TABEL ..... **xi**
DAFTAR GAMBAR ..... **xii**
DAFTAR RUMUS ..... **xiii**
DAFTAR LAMPIRAN ..... **xiv**
1. PENDAHULUAN **1**
1.1 Latar Belakang 1
1.2 Ruang Lingkup 2
1.3 Tujuan Penelitian 2
1.4 Sistematika Penulisan 2
2. TINJAUAN PUSTAKA **4**
2.1 Penelitian Terdahulu 4
2.2 *Artificial Intelligence (AI)* 8
2.3 *Deep Learning* 9
2.4 *Machine Learning (ML)* 10
2.5 *Convolutional Neural Network (CNN)* 12
2.5.1 *Convolutional Layer* 13
2.5.2 *Pooling Layer* 14
2.5.3 *Fully Connected Layer* 14
2.6 Pengolahan Citra 15
2.7 *Python* 15
2.9 *Google Colaboratory (google colab)* 16

2.10 *Google Drive* 17
2.11 *Roboflow* 18
2.12 *Dataset* 19
2.13 *Tensorflow* 20
2.14 *NumPy* 21
2.15 Pandas 22
2.16 Keras 22
2.17 Augmentasi Data 23
2.18 Pemisahan Data 24
2.18.1 Data *Training* 24
2.18.2 Data *Validation* 25
2.18.3 Data *Testing* 25
2.19 Kaggle 26
2.20 *Confusion Matrix* 26
2.21 *MobileNetV2* 28
2.22 *Flowchart* 29
2.23 Tumbuhan 31
2.23.1 Monokotil 32
2.23.2 Dikotil 35
3. METODE PENELITIAN 35
3.1 Tahapan Penelitian 35
3.2 Analisis Kebutuhan 36
3.1.1 Kebutuhan Perangkat Lunak 37
3.1.2 Kebutuhan Perangkat Keras 37
3.1.3 Kebutuhan *Library* 37
3.1.4 Kebutuhan Data 38
3.3 Data *Preparation* 38
3.3.1 Pembersihan Data 39
3.3.2 *Preprocessing* dan Pelabelan Data 40
3.3.3 Augmentasi Data 42
3.3.4 Pembagian Data 43
3.4 Modeling 44

3.4.1 Arsitektur MobileNetV2 44
3.4.2 Pelatihan Membentuk Model 46
3.4.3 Pengujian pada Model 47
3.5 Evaluation 47
4. HASIL DAN PEMBAHASAN 49
4.1 Hasil Persiapan Data 49
4.1.1 Data Penelitian 49
4.1.2 Hasil Data Penelitian 51
4.2 Data Preparation 52
4.2.1 Pembersihan Data 53
4.2.2 *Preprocessing* dan Pelabelan Data 53
4.2.3 Augementasi Data 56
4.2.4 Pembagian Data (*Split Data*) 57
4.3 Arsitektur dan Pelatihan Model 58
4.4 Hasil Eksperimen dan Evaluasi Model 58
4.4.1 Hasil Pelatihan Model 58
4.4.2 Hasil Evaluasi 59
4.4.3 *Confusion Matrix* dan Metrik Kinerja 63
4.5 Hasil Pengujian Data dan Akurasi 64
5. PENUTUP 69
5.1 Kesimpulan 69
5.2 Saran 69
DAFTAR PUSTAKA 71
LAMPIRAN L-1
Listing Program L-1
Output Program L-7

DAFTAR TABEL

Tabel 2. 1 Tabel Penelitian Terdahulu 4
Tabel 2. 5 Penjelasan Flowchart 30
Tabel 2. 2 Perbedaan Antara Tumbuhan Dikotil dan Monokotil 31
Tabel 2. 3 Contoh Tumbuhan Monokotil 33
Tabel 2. 4 Contoh Tumbuhan Dikotil 36
Tabel 3. 1 Kebutuhan Perangkat Lunak 37
Tabel 3. 2 Kebutuhan Perangkat Keras 37
Tabel 3. 3 Daftar Library Python yang digunakan 37
Tabel 4. 1 Nilai TP, FN, FP, dan TN Per kelas. 60
Tabel 4. 2 Perhitungan *Precision* Per Kelas 61
Tabel 4. 3 Perhitungan *Recall* Per Kelas. 61
Tabel 4. 4 Perhitungan F1-*Score* Per Kelas. 62
Tabel 4. 5 Perhitungan *Macro Average*. 62
Tabel 4. 6 Laporan Klasifikasi Model 64
Tabel 4. 7 Hasil Prediksi Label 65

DAFTAR GAMBAR

Gambar 2. 1 Ilustrasi Ekstrasi Fitur Deep Learning 10
Gambar 2. 2ilustrasi Ekstrasi Fitur Machine Learning 11
Gambar 2. 3 proses Convolutional Neural Network (CNN)..... 13
Gambar 2. 4 Contoh Proses Pooling pada Max Pooling 14
Gambar 2. 5 bahasa pemrograman python..... 16
Gambar 2. 9 Tampilan Google Colab 17
Gambar 2. 10 tampilan Google Drive 18
Gambar 2. 11 Logo TensorFlow 21
Gambar 2. 12 Logo Pandas 22
Gambar 2. 13 Tabel Confusion matrix..... 27
Gambar 3. 1 Tahapan Penelitian 35
Gambar 3. 2 Gambar Daun Dikotil dan Daun Monokotil..... 39
Gambar 3. 3 Citra Daun yang tidak bagus 39
Gambar 3. 4 Proses Labelling Daun Dikotil 41
Gambar 3. 5 Proses Labelling Daun Monokotil..... 41
Gambar 3. 6 Jumlah pelabelan data 41
Gambar 3. 7 Proses augmentasi pada roboflow..... 42
Gambar 3. 8 Pembagian Data Training, Validation, dan Testing di Roboflow 44
Gambar 3. 9 Diagram Arsitektur Model MobileNetV2..... 46
Gambar 4. 1 Tampilan *Website Kaggle* 49
Gambar 4. 2 Pencarian bentuk daun dikotil dan monokotil..... 50
Gambar 4. 3 Hasil pencarian data daun dikotil dan monokotil..... 50
Gambar 4. 4 Tampilan Dataset daun dikotil dan monokotil 51
Gambar 4. 5 Tampilan gambar data daun dikotil..... 52
Gambar 4. 6 Tampilan gambar data daun monokotil..... 52
Gambar 4. 7 *Prepocessing* pada roboflow 53
Gambar 4. 8 Tampilan awal roboflow 54
Gambar 4. 9 Tampilan untuk *create project* roboflow 54
Gambar 4. 10 Isi folder "*Image*" pada roboflow..... 55
Gambar 4. 11 Tampilan citra daun telah berhasil diberi label 56
Gambar 4. 12 Proses Augmentasi pada roboflow..... 57
Gambar 4. 13 Proses *split dataset* pada roboflow..... 58
Gambar 4. 14 Grafik Akurasi dan *Loss* pelatihan dan validasi..... 59
Gambar 4. 15 *Confusion Matrix* Hasil Pengujian Model..... 63

DAFTAR RUMUS

Rumus 2. 1 *Accuracy* 27
Rumus 2. 2 *Precision* 27
Rumus 2. 3 *Recall* 28
Rumus 2. 4 *Specifity* 28
Rumus 2. 5 *F1-Score* 28

DAFTAR LAMPIRAN

Listing Program……..L-1

Output Program……..L-7

1. PENDAHULUAN

1.1 Latar Belakang

Tumbuhan merupakan salah satu komponen penting dalam ekosistem yang memiliki peran vital dalam menjaga keseimbangan lingkungan serta mendukung kehidupan berbagai organisme di bumi. Salah satu klasifikasi utama dalam dunia tumbuhan adalah pembagian antara tumbuhan dikotil dan monokotil, yang didasarkan pada berbagai ciri morfologi seperti bentuk daun, struktur akar, batang, dan bunga. Tumbuhan dikotil umumnya memiliki daun dengan pola tulang daun menjari atau menyirip, sedangkan tumbuhan monokotil memiliki daun dengan pola tulang daun sejajar klasifikasi tradisional yang dilakukan secara manual oleh ahli botani memiliki beberapa keterbatasan.

Proses ini memerlukan waktu yang lama, membutuhkan keahlian khusus, dan rentan terhadap kesalahan subjektivitas. Dengan meningkatnya jumlah spesies tanaman, terutama di negara dengan keanekaragaman hayati tinggi seperti Indonesia, diperlukan metode yang lebih efisien dan akurat untuk klasifikasi tanaman.

Metode *Convolutional Neural Network* (CNN) salah satu arsitektur *deep learning* yang sangat efektif dalam pengolahan citra digital. Dengan kemampuan ekstarasi fitur secara otomatis dan hierarkis, CNN dapat mengklasifikiasi jenis daun pada citra tanaman obat dengan tingkat akurasi yang tinggi. Penelitian terkini menunjukkan bahwa model CNN dapat mencapai akurasi lebih dari 90% dalam klasifikasi jenis tanaman dikotil dan monokotil dengan kecepatan dan ketepatan yang dapat membantu petani dalam pengambilan keputsan secara langsung (Baiju et al., 2025).

Penelitian ini berfokus pada pengembangan sistem klasifikasi tumbuhan dikotil dan monokotil berdasarkan bentuk daun menggunakan metode CNN. Dengan memanfaatkan teknologi ini, diharapkan dapat menyediakan alat bantu yang akurat dan mudah digunakan untuk identifikasi

tumbuhan yang berguna dalam pendidikan, penelitian, dan aplikasi praktis di lapangan.

1.2 Ruang Lingkup

Berdasarkan latar belakang di atas, ruang lingkup pada penelitian ini sebagai berikut :

1. *Dataset* yang digunakan berasal dari *website Kaggle* yang berisi sebanyak 1201 *dataset*.
2. Kelas klasifikasi dibagi menjadi dua jenis kelas yaitu kelas dikotil sebanyak 603 dan monokotil sebanyak 598.
3. Penelitian ini hanya berfokus pada citra bentuk daun Dikotil dan Monokotil.
4. Pengolahan dan analisis data dilakukan menggunakan *platform Google Colaboratory (Google Colab)* dengan bahasa pemrograman *Python*.
5. Penelitian ini mengimplementasikan metode *Convolutional Neural Network*.

1.3 Tujuan Penelitian

Berdasarkan ruang lingkup tersebut, maka tujuan dari penelitian ini adalah sebagai berikut:

1. Merancang arsitektur *Convolutional Neural Network* yang efektif untuk mengklasifikasikan jenis tumbuhan dikotil dan monokotil.
2. Melakukan evaluasi model *Convolutional Neural Network* yang dibangun untuk mengklasifikasikan jenis tumbuhan dikotil dan monokotil.
3. Memudahkan ahli botani dalam mengklasifikasikan tanaman dikotil dan monokotil.

1.4 Sistematika Penulisan

Sistematika penulisan yang dilakukan oleh penulis ini dijelaskan dalam lima bab yang membahas masalah secara singkat, diperlukan sistematika

penulisan yang berurutan secara garis besar. Adapun sistematika penulisan disusun terdiri dari bagian.

Pendahuluan berisi latar belakang dari penelitian yang dilakukan, ruang lingkup yang memberikan batasan masalah yang dikaji, tujuan penelitian, dan sistematika penulisan.

Tinjauan pustaka berisi referensi yang mendukung penulisan ini diantaranya mengenai *Google Colab, Deep Learning, Machine Learning, Convolutional Neural Network, Python,* Daun Dikotil dan Monokotil, dan Studi Literatur.

Metode Penelitian yang menguraikan secara detail metode penelitian, mulai dari pengumpulan data, *preprocessing*, pengembangan model, hingga evaluasi.

Hasil dan Pembahasan berisi tentang hasil eksperimen, analisis performa model, yang meliputi akurasi mode dan evaluasi metrik yang didasarkan pada *confusion matrix*.

Penutup. Bagian penutup berisi kesimpulan yang telah diteliti, serta saran yang ditunjukkan untuk pengembangan penelitian kedepannya.

2. TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Pada sub bab ini, akan diuraikan sejumlah penelitian terdahulu yang relevan dengan topik yang dibahas. Penelitian terdahulu berperan penting dalam memberikan landasan teoritis, serta pemahaman mendalam mengenai berbagai konsep dan metode yang telah diterapkan dalam penelitian sebelumnya. Melalui kajian terhadap penelitian terdahulu, dapat diidentifikasi berbagai temuan yang mendukung, serta memberikan arah bagi pengembangan penelitian ini. Pada Tabel 2.1 adalah penelitian terdahulu yang relevan dengan penelitian ini.

Tabel 2. 1 Tabel Penelitian Terdahulu

No	Judul	Peneliti	Hal Yang Dianalisis	Kekurangan	Kelebihan
1	Klasifikasi Penyakit Mata Menggunakan Convolutional Neural Network (CNN) Sumber: (SISTEMASI: Jurnal Sistem Informasi) 2021	Fani Nurona Cahya, Nila Hardi, Dwiza Riana, Sri Hadianti	Penggunaan arsitektur AlexNet untuk meningkatkan akurasi klasifikasi.	Dataset yang digunakan mungkin tidak cukup beragam untuk generalisasi yang lebih baik di populasi yang lebih luas.	Memanfaatkan perkembangan terkini dalam deep learning dan CNN, yang relevan dengan tren penelitian saat ini.
2	Penerapan Convolutional Neural Network pada Citra Rontgen Paru-Paru untuk Deteksi SARS-CoV-2 Sumber: (Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi) 2021	Bambang Pilu Hartato	Mengukur performa CNN dalam mengklasifikasikan citra rontgen paru-paru untuk mendeteksi COVID-19.	Kualitas citra rontgen yang digunakan dapat memengaruhi hasil, dan tidak ada pembahasan mengenai bagaimana menangani citra berkualitas rendah.	Hasil akurasi yang sangat tinggi menunjukkan efektivitas model CNN dalam mendeteksi COVID-19 melalui citra rontgen.
3	Klasifikasi Deteksi Penggunaan	Nalda Kresimo Negoro,	Menganalisis efektivitas metode CNN	Dataset pengujian yang	Hasil evaluasi menunjukkan akurasi yang

No	Judul	Peneliti	Hal Yang Dianalisis	Kekurangan	Kelebihan
	Masker Menggunakan Metode Convulitional Neural Network. Sumber: (JIPI (Jurnal Ilmiah Penelitian dan Pembelajaran Informatika) 2023	Ema utami, Ainul Yaqin	dalam mendeteksi penggunaan masker pada wajah, terutama dalam konteks era Industri 5.0.	digunakan hanya terdiri dari 16 gambar, yang mungkin tidak cukup untuk menilai generalisasi model secara menyeluruh.	sangat tinggi, membuktikan efektivitas model dalam klasifikasi.
4	Optimasi Akurasi Metode Convolutional Neural Network untuk Identifikasi Jenis Sampah. Sumber: Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi) 2021	Rima Dias Ramadhani, Afandi Nur Aziz Thohari,	Menganalisis dan mengoptimalkan metode CNN untuk mengidentifikasi jenis sampah, yaitu organik dan anorganik.	Dataset pengujian yang hanya terdiri dari 34 gambar mungkin tidak cukup untuk menilai generalisasi model secara komprehensif.	Penjelasan yang jelas tentang langkah-langkah penelitian, dari pengumpulan data hingga evaluasi model, membuatnya mudah dipahami.
5	Penerapan Convolutional Neural Network Deep Learning dalam Pendeteksian Citra Biji Jagung Kering Sumber: Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi) 2021	Atum TiaraSari, Emy Haryanti	Menerapkan metode CNN untuk mendeteksi jenis biji jagung kering dalam konteks industri, terutama untuk pemilahan dan pengemasan.	Penelitian tidak membahas bagaimana model berfungsi dalam kondisi pencahayaan atau sudut pandang yang berbeda, yang dapat mempengaruhi akurasi.	Hasil penelitian menunjukkan akurasi yang baik, yang menunjukkan efektivitas model dalam mendeteksi biji jagung kering.
6	Sistem Deteksi Wajah Untuk	Syifa Zahrah, Azhar,	Membangun sistem deteksi wajah yang	Tidak ada analisis tentang	Penelitian ini relevan dengan kebutuhan sistem

No	Judul	Peneliti	Hal Yang Dianalisis	Kekurangan	Kelebihan
	Pencatatan Kehadiran Mahasiswa Di Kelas Menggunakan Metode Convolutional Neural Network Sumber: (Journal of Artificial Intelligence and Software Engineering (J-AISE) 2021	Musta inul Abdi	dapat digunakan untuk pencatatan kehadiran mahasiswa di kelas secara otomatis menggunakan CNN.	bagaimana perubahan kondisi pencahayaan atau sudut pandang dapat mempengaruh i akurasi deteksi.	absensi yang efisien dan otomatis di lingkungan pendidikan.
7	Deteksi Pengenalan Jenis Beras Menggunakan Metode Convolutional Neural Network Sumber: JATI (Jurnal Mahasiswa Teknik Informatika) 2023	Satria Tegar Prabowo, Wiwien Hadikurni awati	Menerapkan metode CNN untuk mengidentifik asi berbagai jenis beras secara otomatis, membantu dalam pemilahan dan pengemasan.	Jurnal tidak membahas bagaimana kondisi pencahayaan atau sudut pengambilan gambar dapat mempengaruh i akurasi deteksi.	Hasil akurasi yang tinggi menunjukkan efektivitas model dalam mengidentifikasi jenis beras, yang penting untuk aplikasi industri.
8	Deteksi Penyakit pada Daun Kentang Menggunakan Pengolahan Citra dengan Metode Convolutional Neural Network Sumber: (Creative Information Technology Journal) 2021	Abdul Jalil Rozaqi, Andi Sunyoto, Rudyanto Arief	Membangun sistem untuk mendeteksi penyakit pada daun kentang, yaitu late blight dan early blight, menggunakan metode CNN.	Risiko overfitting yang mungkin terjadi tidak dibahas, terutama karena model memiliki akurasi tinggi pada dataset pelatihan	Hasil akurasi yang tinggi menunjukkan efektivitas metode CNN dalam mendeteksi penyakit pada daun kentang.

No	Judul	Peneliti	Hal Yang Dianalisis	Kekurangan	Kelebihan
9	Deteksi Pemakaian Helm Proyek Dengan Metode Convolutional Neural Network Sumber: (Journal of Intelligent System and Computation) 2021	Bambang Widodo, Hendrawan Armanto, Endang Setyati	Membangun sistem yang dapat mendeteksi apakah pekerja konstruksi menggunakan helm proyek untuk meningkatkan keselamatan kerja.	Tidak ada analisis tentang bagaimana kondisi pencahayaan dan sudut pandang dapat mempengaruhi akurasi deteksi.	Penelitian ini sangat relevan dengan kebutuhan industri konstruksi untuk meningkatkan keselamatan kerja pekerja.
10	Implementasi Metode Convolutional Neural Network untuk Mendeteksi Penyakit pada Citra Daun Tomat Sumber: (Jurnal Pekommas) 2022	Chrisno R. Kotta, Debby Paseru, Michael Surmampouw	Mendeteksi penyakit pada daun tomat, yaitu late blight dan early blight, melalui citra daun menggunakan metode CNN.	Tidak ada analisis tentang bagaimana faktor pencahayaan atau kondisi lingkungan dapat mempengaruhi akurasi deteksi.	Hasil akurasi yang tinggi menunjukkan efektivitas metode CNN dalam pengenalan pola pada citra daun.

Berdasarkan jurnal terkait, penelitian pertama sampai dengan sepuluh pembahasan mengenai Implentasi metode *Convolutional Neural Network* dan terdapat juga kelebihan dan kekurangan nya pada masing-masing jurnal. Berdasarkan beberapa batasan tersebut penelitian ini membuat tema Implementasi Metode *Convolutional Neural Network* (CNN) Pada Sistem Klasifikasi Tumbuhan Dikotil Dan Monokotil Berdasarkan Citra Bentuk Daun.

2.2 *Artificial Intelligence (AI)*

Artificial Intellegence (AI), yang dikenal sebagai kecerdasan buatan dalam terminology yang lebih tepat, mengacu pada perkembangan teknologi yang mampu meniru kemampuan berfikir dan bertindak seperti manusia. Kata "*Artificial"* dalam AI merujuk pada sesuatu yang dibuat oleh manusia, sedangkan "*Intellegence"* menggambarkan atribut kecerdasan (Farwati et al., 2025).

Kecerdasan buatan secara sederhana didefinisikan sebagai perangkat untuk membantu manusia dengan pemikiran dan penalaran yang sejalan dengan instruksi dari manusia itu sendiri. AI merupakan kecerdasan buatan yang superior dibandingkan manusia dalam hal ketepatan dan presisi, terlihat dari kemampuan AI dalam bersaing dengan kecepatan manusia bahkan melebihinya, dan ketepatan AI dalam menjalankan program yang tidak diragukan. Menurut Liao, *Artificial Intellegence* (AI) menggunakan penghetahuan lanjutan yang khusus untuk mengalihkan tugas-tugas dari manusia kedalam komputer, dengan tujuan memecahkan masalah atau memberikan saran.

AI dibangun berdasarkan sistem yang memiliki keahlian serupa manusia pada ranah tertentu disebut dengan soft computing. Soft computing merupakan perubahan baru dalam membangun sistem cerdas yang mampu menyelesaikan dan bekerja lebih baik jika terjadi perubahan pada lingkungan . Terdapat 3 metode yang dikembangkan dalam *AI* menurut(Alhamdani, 2022). :

1. *Fuzzy Logic* (*FL*)

   Teknik fuzzy logic merupakan teknik yang digunakan oleh mesin untuk mengadaptasi bagaiman mahluk hidup menyesuaikan kondisi dengan memberikan keputusan yang tidak kaku 0 atau 1.

2. *Evolutionary Computing* (*EC*)

   Pendekatan ini menggunakan skema evolusi yang menggunakan jumlah individu yang banyak dan memberikan sebuah ujian untuk menyeleksi individu terbaik untuk membangkitkan generasi selanjutnya. Seleksi tersebut digunakan untuk mencari solusi dari suatu permasalahan.

3. *Machine Learning* (*ML*)

Machine learning merupakan teknik yang paling populer dikarenakan banyak digunakan untuk menggantikan atau menirukan perilaku manusia untuk menyelesaikan masalah. Sesuai dengan namanya, *ML* akan mencoba untuk menirukan bagaimana proses manusia atau mahluk cerdas belajar dan mengeneralisasi.

2.3 *Deep Learning*

Deep Learning, adalah sebuah bagian dalam *Machine Learning,* memberikan pelatihan pada komputer untuk melaksanakan tugas-tugas seperti yang dilakukan manusaia dengan menggunakan model matematika yang terimspirasi oleh jaringan saraf otak manusia. Ini memungkinkan komputer untuk menganalisis data lebih mendalam, menghasilkan hasil analisis yang lebih akurat (Ardianto & Wibisono, 2022). Konsep ini memilki penerapan yang signifikan dalam berbagai bidang, termasuk analisis gambar, pemrorsesan bahasa alami, dan prediksi pola pada data berskala besar (Mochamad Reza et al., 2023).

Deep learning adalah bagian dari pembelajaran mesin yang berkaitan dengan algoritma dimana cara kerja dari algoritma ini meniru struktur dan fungsi otak yang disebut jaringan saraf tiruan. Penelitian terkait *deep learning* telah banyak dilakukan dalam berbagai bidang. Seperti misalnya dibidang sosial, ekonomi dan bahkan hingga masalah emosi, *music* juga *social media*. Beberapa penelitian terkait bidang kesehatan adalah deteksi kanker payudara, deteksi covid, tumor otak, klasifikasi *image* medis dan sebagainya (Rochmawati et al., 2021).

Sistem mengevaluasi data untuk mengidentifikasi pola dan membuat prediksi. Algoritma pembelajaran semi-terawasi menggabungkan data tanpa label dan pelatihan berbasis manusia, yaitu sumber daya online berlabel disediakan untuk memetakan input dan output tertentu dengan akurasi yang lebih tinggi. Algoritma pembelajaran penguatan melibatkan tugas atau tujuan yang harus diselesaikan sistem. Sepanjang proses ini, sistem menerima umpan balik untuk mempelajari perilaku yang diinginkan untuk pendekatan yang paling efektif melalui sinyal penguatan intuitif. *Deep Learning* juga dapat disebut sebagai pemrograman diferensial. *Deep Learning* telah digunakan dalam berbagai bidang seperti

pengenalan suara, pemrosesan bahasa alami, dan visi komputer, termasuk pengenalan wajah. *Deep Learning* adalah algoritma *multi-layer* yang digunakan untuk mengekstrak fitur dan mengidentifikasi tepi seperti huruf, angka, dan wajah (Amandri Achyar et al., 2022).

Perbedaan antara model *Machine Learning* dan *Deep Learning* adalah pada ekstraksi fitur. *Machine Learning* ekstraksi fitur dilakukan oleh manusia sedangkan pada *Deep Learning*, ekstraksi fitur dilakukan oleh model itu sendiri. Pada Gambar 2.1 Ilustrasi Ekstraksi Fitur Deep Learning.

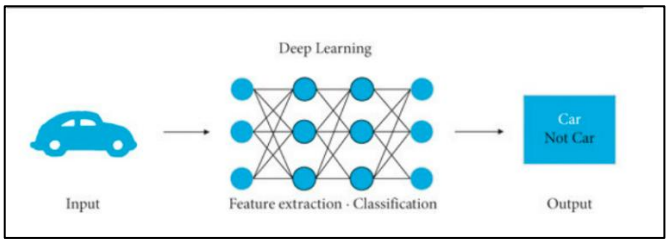

Gambar 2. 1 Ilustrasi Ekstrasi Fitur Deep Learning
(sumber: Illustration of machine learning and deep learning. | Download Scientific Diagram)

2.4 *Machine Learning (ML)*

Machine learning merupakan cabang dari ilmu komputer yang menggabungkan berbagai macam disiplin ilmu dalam pengembangannya, seperti ilmu komputer, ilmu statistik dan ilmu matematika. Secara umum *machine learning* bertujuan untuk membuat sebuah program yang dapat belajar sendiri dari pengalaman atau data yang diberikan sebagai bahan ajar mesin atau program tersebut. *Machine learning* memiliki beberapa jenis pendekatan dan algoritma berbeda yang dapat digunakan untuk mengatasi berbagai masalah berbeda. Salah satu contoh pendekatan dari *machine learning* adalah *supervised learning* atau suatu pendekatan di mana program belajar untuk mengklasifikasi atau memprediksi hasil keluaran dari data yang sudah memiliki hasilnya. *Supervised learning* dapat digunakan untuk mengatasi masalah klasifikasi dan regresi. Klasifikasi adalah suatu proses untuk mengklasifikasikan suatu nilai berdasarkan kelas yang sudah ditentukan, sedangkan regresi adalah proses memprediksi niai kontinu (Ningsih, Gusvarizon and Hermawan, 2022).

Machine Learning berfokus pada pengembangan program komputer yang dapat mengakses data dan menggunakanya untuk belajar sendiri. *Machine Learning* adalah bagian dari kecerdasan buatan dimana bertujuan guna memahami dan mengenali struktur suatu data kemudian mengkonversi data tersebut kedalam suatu model. *Machine Learning* dapat menguraikan data serta mampu belajar secara mandiri melalui proses *training*. Dalam proses ini akan didapatkan model untuk digunakan menjawab input data yang disesuaikan dari hasil training model. Beberapa bidang yang menggunakan *Machine Learning* seperti pengenalan suara, objek, wajah, penerjemahan dan lain sebagainya (Ningsih, Gusvarizon and Hermawan, 2022).

Machine Learning membantu menangani dan memprediksi data yang sangat besar dengan cara merepresentasikan data-data tersebut dengan algoritma pembelajaran. *Machine Learning* dapat membantu komputer memprogram diri mereka sendiri. Pemrograman adalah pekerjaan untuk membuat otomatis, maka *Machine Learning* mengotomatisasi proses otomatis (Murphy, 2022). Pada Gambar 2.2 ilustrasi Ekstrasi Fitur *Machine Learning*.

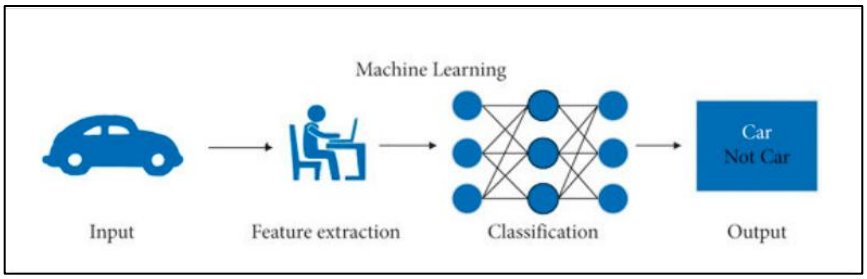

Gambar 2. 2 ilustrasi Ekstrasi Fitur Machine Learning.
(sumber: Illustration of machine learning and deep learning. | Download Scientific Diagram).

Klasifikasi adalah metode dalam *Machine Learning* yang digunakan oleh mesin untuk memilah atau mengklasifikasikan obyek berdasarkan ciri tertentu sebagaimana manusia mencoba membedakan benda satu dengan yang lain. Prediksi atau regresi digunakan oleh mesin untuk memprediksi keluaran dari suatu data masukan berdasarkan data yang sudah dipelajari dalam training. (Savitri et al., 2021).

Ada empat jenis cara pembelajaran pada *Machine Learning*, yaitu:

1. *Supervised Learning*, data pembelajaran mencakup keluaran yang sudah ditentukan.
2. *Unsupervised Learning*, data pembelajaran tidak mecakup keluaran yang sudah di tentukan.
3. *Semi-supervised Learning*, data pembelajaran mencakup beberapa keluaran yang ditentukan
4. *Reinforcement Learning*, pemberian hadiah dari setiap serangkaian tindakan yang dilakukan.

2.5 *Convolutional Neural Network (CNN)*

Convolutional Neural Network (CNN) adalah model *Deep Learning* yang digunakan untuk menganalisis gambar, dengan mengandalkan pembagian bobot untuk mengurangi parameter pelatihan dan mencegah *overfitting*. *CNN* menonjol dalam identifikasi objek dan deteksi pola visual yang kompleks, mengekstrak elemen-elemen penting dari gambar sambil meningkatkan efisiensi komputasi (Alhamdani, 2022). Kemampuan *CNN* dalam membagi bobot membuatnya sangat sesuai untuk tugas pemrosesan gambar *real-time*, seperti dalam aplikasi pengenalan wajah dan mobil otonom. Meskipun demikian, implementasi yang efektif memerlukan pertimbangan yang hati-hati terhadap desain arsitektur, pemilihan parameter, dan manajemen data pelatihan. Dengan penelitian lebih lanjut, *CNN* telah menjadi alat yang tidak tergantikan dalam penelitian ilmiah terkait pemrosesan gambar dan pemahaman visual (Jack Billie Chandra and Dewi Nasien, 2023). Pada Gambar 2.3 proses *Convolutional Neural Network (CNN)*.

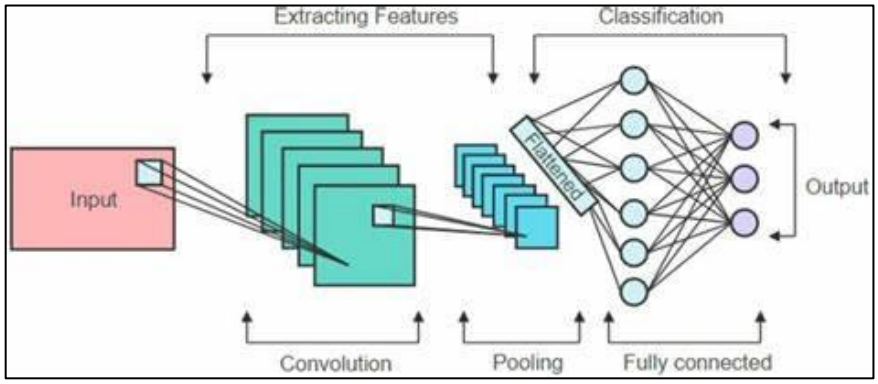

Gambar 2. 3 proses Convolutional Neural Network (CNN).
(sumber: Basic CNN Architecture. | Download Scientific Diagram).

CNN memiliki lapisan *input,* lapisan *output*, dan diantara kedua lapisan tersebut *hidden layer.* Setiap lapisan memiliki banyak neuron yang saling terhubung, dimana setiap neuron akan memberikan nilai pembobotan guna mencapai bentuk fungsi yang diharapkan. Dalam *hidden layer* sebuah *CNN*, ada 3 jenis lapisan umumnya digunakan, yaitu lapisan konvolusi, lapisan *pooling,* dan lapisan *fully connected*.

2.5.1 *Convolutional Layer*

Konvolusi merupakan suatu istilah dari matematis yang berarti mengaplikasikan sebuah fungsi pada output fungsi lain secara berulang. Dalam pengolahan citra, konvolusi berarti mengaplikasikan sebuah kernel(kotak kuning) pada citra di semua *offset* yang memungkinkan. *Convolution Layer* ini melakukan operasi konvolusipada *output* dari *layer* sebelumnya ada. *Layer* proses utama yang mendasari sebuah *CNN*. Lapisan ini adalah lapisan proses konvolusi pada citra, dimana sebuah filer (dengan ukuran dimensi seperti persegi, umumnya berdimensi 3x3) diaplikasikan kepada citra sehingga membentuk keluaran citra dengan angka yang baru pada *pixel*. Jumlah filter yang diaplikasikan pada lapisan ini mempengaruhi banyakmya *feature map* yang akan terbentuk (Pratiwi, Cahyanti and Lamsani, 2021).

2.5.2 Pooling Layer

Lapisan ini digunakan untuk mengurangi dimensi data yang akan digunakan. Lapisan ini sangat berguna jika ukuran dari suatu citra sangat besar. Ada beberapa jenis *pooling* yang bisa digunakan. Setiap jenis *pooling* memiliki karakteristik yang berbeda karena informasi yang disimpan juga berbeda. *Max Pooling*, akan menyimpan nilai yang tebesar dari suatu kelompok data untuk dilanjutkan ketahap selanjutnya. Jenis ini akan menghilangkan nilai lain yang lebih rendah dari nilai maksimal tersebut. *Average pooling*, jenis *pooling* ini akan mencari rata-rata dari seluruh nilai pada suatu kelompok data. Kedua jenis *pooling* tersebut merupakan yang paling sering digunakan. Contoh proses yang terjadi pada *max pooling* dapat dilihat pada Gambar 2.4.

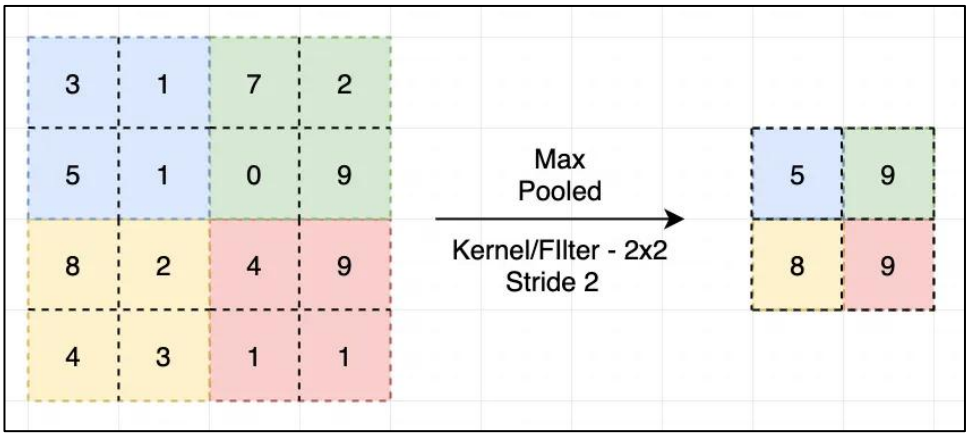

Gambar 2. 4 Contoh Proses Pooling pada Max Pooling
(sumber: https://medium.com/ai-in-plain-english/pooling-layer-beginner-to-intermediate-fa0dbdce80eb).

2.5.3 *Fully Connected Layer*

Pada *convolution layer* diperlukan transformasi menjadi data satu dimensi terlebih dahulu sebelum dapat dimasukkan ke dalam sebuah *Fully Connected layer*. Karena hal tersebut menyebabkan data kehilangan informasi spasialnya dan tidak reversibel, *Fully Connected layer* dapat diimplementasikan di akhir jaringan. Setiap neuron dilapisan ini terhubung ke semua nomor divolume yang lebih rendah (Hidayat, Latifah Husni and Damsi, 2022) dijelaskan bahwa convolution *layer* dengan ukuran kernel 1x1 melakukan fungsi yang sama dengan sebuah *Fully Connected layer* namun dengan tetap dengan mempertahankan karakter spasial dari

data. Hal ini membuat penggunaan *Fully Connected layer* pada *CNN* sekarang tidak banyak dipakai (Pratiwi, Cahyanti and Lamsani, 2021).

2.6 Pengolahan Citra

Pengolahan citra atau *image processing* adalah proses yang melibatkan penggunaan komputer untuk meningkatkan kualitas gambar. Proses ini melibatkan penggunaan algoritma computer untuk mengekstrak informasi penting atau meningkatkan kualitas gambar. Pengolahan citra terdiri dari elemen seperti piksel dan gambar (Gilang Perwati, Suarna and Suprapti, 2024). Citra atau *image* merupakan representasi spasial dari suatu objek yang sebenarnya dalam bidang dua dimensi yang biasanya ditulis dalam koordinat cartesian x-y, dan setiap koordinat merepresentasikan satu sinyal terkecil dari sebuah objek. Fungsi citra yaitu model matematika yangsering digunakan untuk menganalisis dimana semua fungsi analisis dapat digunakan untuk mempertimbangkan citra sebagai fungsi dengan 2 variabel.

Citra adalah gambaran yang terekam oleh sebuah kamera atau oleh sensor. Mengutarakan pengertian tentang citra yaitu: 1. Gambaran obyek yang dibuahkan oleh suatu pantulan atau pembiasan sinar yang difokuskan pada sebuah lensa atau sebuah cermin. 2. Gambaran rekaman suatu obyek (biasanya berupa gambaran pada foto) yang dibuat dengan cara optik, elektro-optik, optik mekanik atau elektronik. Pada umumnya gambar digunakan bila radiasi elektromagnetik yang dipancarkan atau dipantulkan dari suatu obyek tidak langsung direkam pada sebuah film (Sukma and Mukhaiyar, 2022).

2.7 *Python*

Python awalnya dibuat pada akhir tahun 1980 oleh Guido van Rossum, Belanda. Implementasi bahasa pemrograman ini dimulai pada akhir tahun 1989. Pada tahun 2000, *python* 2.0 dirilis dengan banyak fitur utama yang baru. karena sejumlah besar kode tidak dapat dengan mudah dilanjutkan ke *Python* 3, maka tanggal akhir pemakain versi ini yang sebelumnya hanya hingga 2015 diperpanjang menjadi hingga tahun 2020. Pada 2022, perilisan *Python* 3.10.4 dan 3.9.12

dipercepat dikarenakan banyak masalah keamanan. Dan kini Python menjadi salah satu bahasa pemrograman yang cukup banyak dipelajari dan digunakan (Kurnia and Atma, 2022). *Phyton* merupakan sebuah bahasa pemrograman interpreatif Interpreatif merupakan Sebuah program bernama *interpreter* membaca kode sumber baris per baris, menerjemahkannya, lalu langsung menjalankannya. Proses ini terjadi saat program dijalankan. *Pyhton* dianggap sebagai bahasa yang menggabungkan kemampuan dan kejelasan sintaks kode. Bahasa pemrograman *Pyhton* dirancang khusus untuk memudahkan *programmer* dalam membuat program dengan efisiensi waktu, kemudahan pengembanagan, dan kompatibilitas dengan sistem. *Pyhton* juga menyediakan berbagai library dan alat bantu yang kuat untuk analisis data, seperti *Pandas*, *NumPy*, dan *Matplotlib* (Fakhri and Condro Winursito, 2025). Pada Gambar 2.5 contoh tampilan *python*.

Gambar 2. 5 Bahasa pemrograman python.

2.9 *Google Colaboratory (google colab)*

Google Colaboratory, atau sering disebut *Google Colab*, adalah platform berbasis website yang disediakan oleh Google untuk memungkinkan pengguna menulis dan mengeksekusi kode *Python* secara interaktif (Rahman et al., 2023), versi terbaru dari *Google Colab* menawarkan berbagai fitur yang mempermudah proses pengembangan dan penelitian dalam bidang *data science* dan *Machine Learning.* Platform ini mendukung penggunaan *Graphics Processing Unit* (*GPU*) dan *Tensor Processing Unit* (*TPU*), yang sangat penting untuk pelatihan model *Deep Learning* yang memerlukan daya komputasi tinggi. Selain itu, *Google Colab* memungkinkan kolaborasi real-time, mirip dengan *Google Docs*, yaitu beberapa pengguna dapat mengubah dan menjalankan kode dalam satu notebook secara bersamaan. Fitur lain 20 termasuk integrasi langsung dengan *Google drive* untuk

penyimpanan yang mudah, akses ke berbagai *library* dan *framework* populer, serta kemudahan berbagi *notebook* dengan orang lain. Antarmuka yang intuitif dan sumber daya komputasi yang kuat, *Google Colab* menjadi alat yang sangat berguna bagi para peneliti, data scientist, dan pengembang untuk eksperimen cepat dan kolaborasi dalam proyek-proyek berbasis *Python*. *Google Colab* juga telah meningkatkan infrastruktur penyimpanan dan keamanannya, menjadikannya pilihan utama untuk komputasi awan dalam pengembangan aplikasi AI skala besar (Aras, Tanra and Bazhar, 2024). Berikut pada gambar 2.6 tampilan dari *Google Colab*.

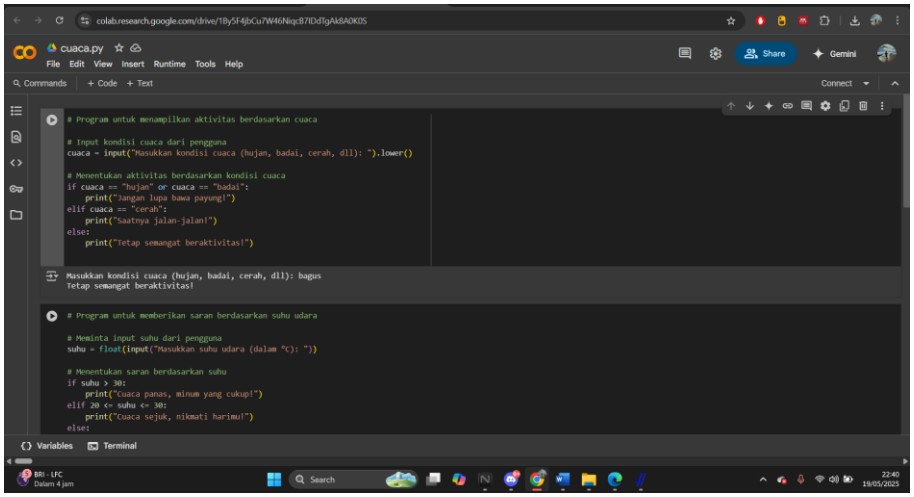

Gambar 2. 6 Tampilan Google Colab.

2.10 *Google Drive*

Google Drive adalah layanan penyimpanan yang berkembang dari *Google Docs* dan kini dimiliki oleh Google Inc. sejak April 2012. Pengguna mendapatkan ruang penyimpanan gratis sebesar 15 *gigabyte* (*GB*) dari layanan ini. Kemudahan dalam menyimpan data seperti gambar, video, dokumen teks, *spreadsheet*, dan presentasi dimungkinkan oleh aksesibilitas yang lancar dari *Google Drive* di berbagai perangkat. *Google Drive* juga bekerja secara tak terlihat dengan produk Google lainnya, seperti *Gmail*, *Google Plus*, dan *Google Search*. Salah satu fitur unggulan *Google Drive* adalah kemampuannya untuk secara otomatis mengidentifikasi objek, baik itu terkait dengan orang atau tempat, dalam berbagai jenis file populer (.txt, .html, .xml, dll.) selama pengindeksan. *Platform* ini juga

menggunakan teknologi pengenalan karakter optik (OCR) untuk menemukan teks dalam foto atau file PDF.

Google Drive adalah *platform* penyimpanan data berbasis awan online yang diperkenalkan pada tanggal 24 April 2012. *Google Drive* tersedia di komputer desktop dan perangkat seluler, sama seperti layanan lain seperti *Dropbox* atau *OneDrive*. *Google Drive*, yang sering dikenal sebagai *GDrive*, sudah terpasang secara *default* sebagai aplikasi pada beberapa *smartphone*. Dengan ruang penyimpanan gratis sebesar 15 *gigabyte*, pengguna dapat menyimpan berbagai jenis file, termasuk dokumen, foto, file audio, dan film. Jika membutuhkan ruang penyimpanan lebih banyak, pengguna dapat meng-upgrade akunnya. File-file dapat disimpan, diubah, dan diambil kembali dari *Google Drive* selama komputer atau smartphone masih terhubung ke internet (Safitri and Nasution, 2023). Berikut tampilan *Google Drive* pada Gambar 2.7

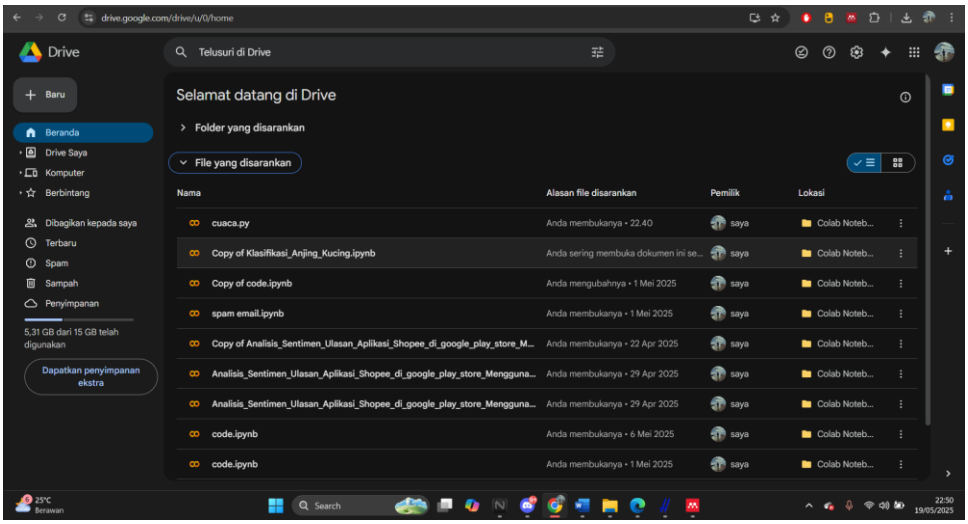

Gambar 2. 7 tampilan Google Drive.

2.11 *Roboflow*

Roboflow merupakan *platform web* yang berfungsi untuk pengelolaan *dataset* secara kompresenhif, mulai dari pengumpulan hingga optimasi data untuk pengembangan model *computer vision*. *Platform* ini menyediakan berbagai alat yang mempermudah proses *preprocessing*, seperti augmentasi data, pengubahan ukuran gambar, anotasi, dan pengolaan *dataset* secara kolaboratif. Selain itu, *Roboflow* juga mendukung pengembangan model dengan teknik agumentasi

otomatis dan konversi *dataset* ke format yang kompatibel dengan berbagai *framework Machine Learning,* termasuk *TensorFlow, PyTorch,* dan YOLO. Dengan fitur tersebut, *Roboflow* menjadi kerangka kerja yang membantu para pengembang dalam meningkatkan efisiensi, kualitas, dan akurasi model *computer vision* secara keseluruhan (Gelar Guntara, 2023).

Gambar 2. 8 Tampilan Roboflow

Sumber: Roboflow.

2.12 *Dataset*

Dataset adalah Kumpulan data yang teroganisisr dan terstruktur yang digunakan untuk analisis dan penelitian. *Dataset* dapat berupa kumpulan data numerik, teks, gambar, suara, atau kombinasi dari beberapa jenis data tersebut. *Dataset* digunakan sebagai input dalam berbagai aplikasi seperti *machine learning, data mining,* dan analisis statistik.

Dataset dapat memiliki berbagai karakteristik seperti ukuran, dimensi, fitur, label, dan keterkaitan antar data. Ukuran *dataset* dapat berupa satu dimensi (misalnya data deret waktu) atau lebih dari satu dimensi (misalnya data tabel dengan kolom dan baris). Fitur *dataset* menggambarkan karakteristik dari setiap data, sedangkan label menunjukkan kategori atau hasil yang diinginkan dari setiap data. Keterkaitan antar data dapat terbentuk melalui hubungan antar data (Aditya Dwi, 2025).

Dataset yang digunakan dalam penelitian ini terdiri dari sejumlah gambar daun dari tumbuhan jenis dikotil dan monokotil yang relevan dengan konteks klasifikasi tumbuhan.

2.13 *Tensorflow*

Tensorflow adalah salah satu library pemrograman yang dikembangkan oleh *Google*, khusus untuk merancang untuk keperluan *machine learning* dan pengembangan model kecerdasan buatan. *Library* ini menjadi salah satu elemen penting dalam bahasa pemrograman *Python* untuk pengembangan aplikasi yang melibatkan analisis data mendalam, pemrosesan citra, pengenalan suara (Ilham and Utaminingrum, 2021).

TensorFlow menyediakan *Object Detection* API untuk mempermudah pengembangan aplikasi Deep Learning untuk membuat perangkat lunak pendeteksian objek. *TensorFlow Object Detection* API adalah *opensource framework* yang dapat digunakan untuk mengembangkan, melatih, dan menggunakan model deteksi objek. Sistem ini sudah banyak diterapkan pada berbagai produk Google antara lain pencarian gambar, deteksi wajah dan plat nomor kendaraan pada *Google Streetview*, *Google Assistant*, Waymo atau self driving car, dan lain-lain (Arifianto, Muhimmah and July Arifianto, 2021).

TensorFlow Object Detection juga menyediakan banyak model yang telah dilatih dengan *dataset Common Object in Context* (COCO) 2017 yang terdiri 16 300.000 gambar berisi 90 kategori objek. Model-model tesebut memiliki kecepatan dan tingkat akurasi masing-masing, sesuai dengan arsiktektur modelnya. Salah satunya adalah model *Solid State Drive (SSD)* ResNet50 V1 FPN 640x640. *SSD* ResNet50 V1 FPN 640x640 merupakan arsitektur deteksi objek FPN *SSD* berdasarkan ResNet-50. ResNet-50 adalah convolution neural network (*CNN*) yang memiliki kedalaman 50 lapisan, ResNet merupakan kependekan dari *residual network*. Setiap unit residual dalam jaringan terdiri dari dua lapisan konvolusi tanpa lapisan penyatuan, normalisasi batch, aktivasi ReLU, dan kernel 3x3. Satu tahapan pada model tesebut menggunakan *Feature Pyramid Network* (*FPN*) back bone pada arsitekturnya. Input dari model *SSD* ResNet50 V1 FPN 640x640 berupa tensor

berukuran 1x640x640x3, ukuran tersbut menunjukan nilai batch size berjumlah 1 dengan gambar *Red, Green, Blue (RGB)* berukuran 640x640. *Output* dari model berupa nama kelas objek, nilai probabilitas, koordinat kotak deteksi, dan jumlah kotak deteksi yang diprediksi (Lu et al., 2021)

Tensorflow memungkinkan para pengembang untuk membangun dan melatih model kecerdasan buatan dengan efisien (Trisiawan, Yuliza and Attamimi, 2022). *Library* ini mendukung berbagai arsitektur jaringan saraf, termasuk *Convolutional Neural Network* (*CNN*) untuk pengenalan citra, *Recurrent Neural Network* (*RNN*) untuk analisis urutan data dan banyak lagi (Trisiawan, Yuliza and Attamimi, 2022).

Gambar 2. 9 Logo TensorFlow
Sumber: https://www.tensorflow.org/extras/tensorflow_brand_guidelines.pdf

2.14 *NumPy*

NumPy merupakan salah satu *library* penting dalam bahasa pemrograman *python* yang berfokus pada pengolahan *array* multidimensi dan operasi matematika yang efisien. Nama umum yang digunakan untuk memanggil *NumPy* adalah “np“. *Library* ini memberikan dasar yang kuat untuk analisis numerik dan ilmiah, memungkinkan manipulasi dara dengan efektif (Ramadhani et al., 2022). *Array* di Numpy mirip dengan list di *python*, tetapi dengan ukuran tetap dan jenis elemen yang sama. Numpy memberikan dukungan untuk *python* dalam hal matriks atau himpunan dengan multidimensi yang cukup besar. Numpy merupakan *library* yang lebih berfokus kepada *scientific computing* (Amandri Achyar et al., 2022). *Numpy* memiliki kemampuan untuk membentuk objek N-*dimensional Array*, yang mirip dengan list pada *python*. Keunggulan Numpy *Array* dibandingkan dengan list pada

python adalah konsumsi *memory* yang lebih kecil serta *runtime* yang lebih cepat. Numpy juga memudahkan kita pada Aljabar Linear, terutama operasi pada Vector (1-d Array) dan Matrix (2-d Array). Numpy adalah pustaka penting untuk pembelajaran mesin dan analisis data karena menyediakan operasi matematis yang efisien dan alat untuk manipulasi data.

2.15 Pandas

Pandas merupakan salah satu pustaka Python yang dirancang untuk memudahkan proses manipulasi dan analisis data. Pustaka ini menyediakan dua struktur data utama, yaitu Series untuk data satu dimensi dan *DataFrame* untuk data dua dimensi. Kedua struktur ini memungkinkan pengolahan data terstruktur secara efisien dan fleksibel. Pandas sering digunakan dalam tahap preprocessing data, pembersihan data, eksplorasi data, serta berbagai aktivitas lain yang berkaitan dengan pengolahan dan analisis data.

Gambar 2. 10 Logo Pandas
Sumber: https://github.com/pandas-dev/pandas

2.16 Keras

Keras merupakan sebuah *Application Programming Interface* (API) tingkat tinggi berbasis *Python* yang dirancang untuk memudahkan pengguna dalam memahami dan membangun model *deep learning*. Dikembangkan secara *open source* sejak Maret 2015, Keras memungkinkan proses pengembangan dan eksperimen dilakukan secara cepat serta efisien

Kelebihan utama dari Keras terletak pada fleksibilitas dan kesederhanaannya dalam penulisan kode, sehingga sangat cocok digunakan baik oleh pemula maupun peneliti yang ingin membuat prototipe model secara cepat.

Keras juga menyediakan berbagai fitur yang dapat langsung digunakan maupun dimodifikasi sesuai kebutuhan pengguna, tanpa harus membangun model dari awal. Beberapa keunggulan Keras antara lain:

1. Menyediakan berbagai fitur yang dapat disesuaikan dengan kebutuhan implementasi.
2. Memungkinkan penggunaan langsung terhadap model bawaan ataupun fitur-fiturnya.
3. Memiliki antarmuka yang sederhana dan mudah dipahami untuk proses implementasi model.
4. Memfasilitasi pengembangan prototipe yang cepat dan dapat digunakan dalam waktu yang relatif singkat.

2.17 Augmentasi Data

Data augmentation merupakan suatu teknik yang digunakan untuk meningkatkan jumlah data dengan melakukan modifikasi terhadap parameter gambar. Modifikasi ini mencakup beberapa transformasi seperti rotasi, skala, dan pembalikan (*flip*). Teknik ini diterapkan untuk meningkatkan akurasi model *Convolutional Neural Network (CNN)* dengan cara memperluas variasi data pelatihan tanpa perlu menambah data asli. Rotasi dilakukan untuk mengubah sudut pandang gambar seolah-olah sedang diputar, skala digunakan untuk memperbesar atau memperkecil tampilan gambar, sedangkan pembalikan dilakukan secara horizontal maupun vertikal guna menambah keberagaman citra yang digunakan dalam proses pelatihan model (Ashari, 2024). Secara teoretis, augmentasi data bertujuan untuk menanamkan *invariance* (kekebalan) terhadap transformasi tertentu pada model. Misalnya, sebuah model klasifikasi gambar seharusnya dapat mengenali seekor kucing terlepas dari orientasi (rotasi), pencahayaan, atau posisinya di dalam gambar. Dengan melatih model pada versi data yang telah diubah (di-augmentasi), model "belajar" untuk mengabaikan variasi yang tidak relevan ini dan fokus pada fitur-fitur semantik yang mendefinisikan kelas objek. Sebuah survei komprehensif dalam *ResearchGate* (2025) menyoroti bahwa tujuan utama augmentasi adalah meningkatkan kuantitas, kualitas, dan keragaman data

pelatihan untuk mengatasi masalah data yang terbatas dan ketidakseimbangan kelas (Westenbroekf et al., 2021). Hubungan antara augmentasi data dan CNN untuk klasifikasi gambar adalah fundamental dan sangat simbiosis. CNN adalah arsitektur *deep learning* yang sangat kuat untuk tugas-tugas visual karena kemampuannya mengekstraksi fitur hirarkis dari gambar (dari tepi sederhana hingga bentuk kompleks). Namun, kekuatan ini juga menjadi kelemahannya: CNN memiliki jutaan parameter, yang membuatnya sangat rentan terhadap *overfitting*, terutama ketika dilatih dengan dataset yang ukurannya terbatas.

Overfitting terjadi ketika model tidak mempelajari fitur umum dari suatu objek, melainkan "menghafal" gambar-gambar spesifik dalam set pelatihan, termasuk noise dan kebetulan yang ada di dalamnya. Akibatnya, model berkinerja sangat baik pada data yang sudah pernah dilihatnya, tetapi gagal total saat dihadapkan pada gambar baru yang belum pernah dilihat sebelumnya (Westenbroekf et al., 2021).

2.18 Pemisahan Data

Dalam proses pembangunan model klasifikasi, pemisahan data merupakan tahap penting yang dilakukan untuk menguji kemampuan model dalam mengenali pola secara umum. Data yang tersedia dibagi menjadi tiga bagian, yaitu data Training, data validasi, dan data Testing. Masing-masing bagian memiliki peran penting dalam pelatihan dan evaluasi model, berikut penjelasannya:

2.18.1 Data *Training*

Training adalah kumpulan data yang digunakan dalam proses pelatihan model klasifikasi agar model dapat mempelajari pola dan karakteristik dari data tersebut secara efektif (Darmawan and Amini, 2022). Ini adalah porsi terbesar dari dataset (biasanya 60%-80%) yang digunakan untuk "mengajari" model. Selama fase training, model (misalnya CNN) akan melihat data ini beserta labelnya secara berulang-ulang. Tujuannya adalah agar model belajar mengenali pola yang mendasari data dengan menyesuaikan parameter internalnya (bobot dan bias) untuk meminimalkan kesalahan (*loss*) prediksi (Wartumi, Kurniawan and Wijaya, 2024).

2.18.2 Data *Validation*

Data validasi merupakan data yang tidak dilibatkan dalam proses pelatihan model. Jika akurasi pada data validasi menunjukkan hasil yang rendah, kemungkinan model mengalami overfitting, sehingga perlu dilakukan penyesuaian ulang terhadap arsitektur jaringan. Sebaliknya, apabila hasil validasi sudah memuaskan, maka model dapat dilanjutkan untuk mengolah data uji (Ashari, 2024). Bagian data yang lebih kecil (sekitar 10%-20%) yang dipisahkan dari data training. Data ini tidak digunakan untuk melatih parameter model secara langsung. Sebaliknya, data validasi digunakan untuk dua tujuan utama selama proses pelatihan:

1. Mendeteksi *Overfitting*: Setelah setiap *epoch* (satu siklus penuh pelatihan pada data training), kinerja model dievaluasi pada data validasi. Jika akurasi pada data training terus meningkat sementara akurasi pada data validasi mandek atau menurun, ini adalah tanda jelas bahwa model mulai *overfitting*. Fenomena ini menjadi sinyal untuk menghentikan pelatihan lebih awal (*early stopping*).
2. Menyesuaikan *Hiperparameter*: Data validasi digunakan untuk menyetel *hyperparameter* model, seperti laju pembelajaran (*learning rate*), jumlah lapisan pada jaringan saraf, atau kekuatan regularisasi. Kita memilih kombinasi hiperparameter yang memberikan kinerja terbaik pada set validasi.

2.18.3 Data *Testing*

Data testing merupakan data yang digunakan untuk melakukan pengujian terhadap model klasifikasi yang telah dibangun dan dilatih sebelumnya menggunakan data training (Darmawan and Amini, 2022). Ini adalah bagian terakhir dari dataset (sekitar 10%-20%) yang disembunyikan sepenuhnya selama proses training dan validasi. Data ini hanya digunakan satu kali setelah model selesai dilatih dan semua hiperparameter telah ditentukan. Tujuannya adalah untuk memberikan evaluasi akhir yang objektif dan tidak bias tentang seberapa baik kinerja model pada data baru yang belum pernah dilihat sama sekali. Skor akurasi pada set inilah yang dilaporkan sebagai performa final model.

2.19 Kaggle

Kaggle.com adalah sebuah platform daring yang menjadi wadah bagi para praktisi data untuk saling bertukar pikiran, mencari inspirasi, dan berkompetisi dengan sesama ilmuwan data. Situs ini juga menyediakan sarana untuk mempelajari pengetahuan baru, trik pemrograman, serta melihat berbagai contoh penerapan ilmu data dalam kasus nyata. Ada banyak sekali kumpulan data yang tersedia, mulai dari yang sederhana hingga yang kompleks dan krusial. Data yang disediakan bersifat asli dan dapat dijadikan referensi, sehingga sangat berguna untuk melatih dan menguji model dalam sebuah proyek. Selain itu, Kaggle memiliki beragam fitur bermanfaat seperti Data, Kode, Komunitas, Inspirasi, Kompetisi, dan Kursus(Bakti and Firdaus, 2023). Berikut adalah beberapa manfaat dan fitur utama Kaggle:

a. Data

   Kaggle menyediakan ribuan kumpulan data dalam berbagai format seperti CSV, JSON, SQLite, dan BigQuery. Anda dapat dengan mudah mencari dan menemukan data spesifik yang dibutuhkan untuk mengembangkan model. Kumpulan data ini dapat langsung digunakan untuk berbagai keperluan pengembangan ilmu data.

b. Kode

   Situs ini dipenuhi dengan contoh kode dari para penggunanya. Fitur ini memungkinkan Anda untuk dengan mudah menemukan dan mempelajari bagaimana pengguna lain memecahkan masalah serupa. Ini adalah cara yang sangat efektif untuk belajar dan berlatih. Mayoritas pengguna menggunakan bahasa pemrograman Python, namun bahasa lain seperti R, SQLite, dan Julia juga tersedia.

2.20 *Confusion Matrix*

Confusion matrix adalah metode evaluasi yang digunakan untuk mengevaluasi kinerja klasifikasi objek. Model klasifikasi untuk klasifikasi data dengan kelas yang berbeda. Dengan mengukur nilai akurasi, maka akan didapatkan hasil performa dari suatu model klasifikasi tersebut. Hasil akurasi yang didapatkan

dari klasifikasi dapat diketahui dari hasil data latih dan hasil persentase berdasarkan kelompok yang sudah dilatih lalu diklasifikasikan. Hasil uji berdasarkan model klasifikasi akan dianalisis menggunakan tabel, sehingga didapatkan nilai *accuracy*, *recall*, *precision*, dan f1-*score* (Yuniarossy, Hindrayani and Damaliana, 2024). Berikut penjelasan *Confusion matrix* Gambar 2.11

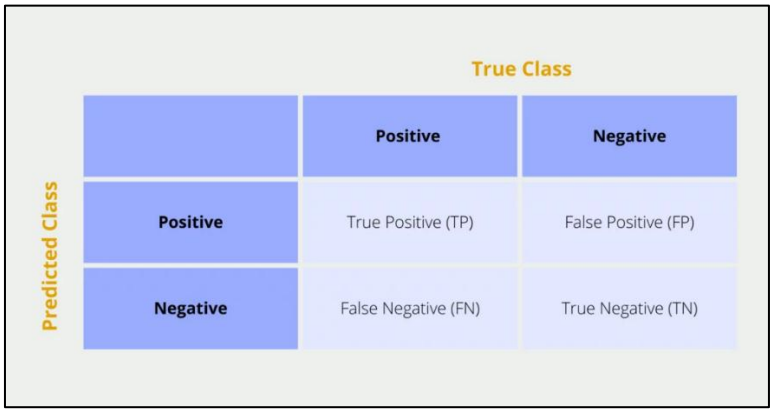

Gambar 2. 11 Tabel Confusion matrix
(sumber: https://databasecamp.de/en/ml/model-evaluation-en).

Keterangan:

- *True Positive* (TP): Hasil prediksi mengklasifikasikan positif dan benar
- *True Negatife* (TN): Hasil prediksi mengklasifikasikan negatif dan benar
- *False Positife* (FP): Hasil prediksi mengklasifikasikan positif, namun salah
- *False Negatife* (FN): Hasil prediksi mengklasifikasikan negatif, namun salah

Performa yang dapat diukur dari metrik diatas antara lain:

a. *Accuracy*

Mengukur tingkat akurasi dari model yang didapat dari total sampel yang berhasil diklasifikasikan benar oleh model tersebut.

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} \quad \ldots\ldots\ldots\ldots\ldots (2.1)$$

b. *Precision*

Mengukur tingkat presisi yang didapat dari hasil prediksi kelas positif dan benar positif.

$$\text{Precision} = \frac{TP}{TP+FP} \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots (2.2)$$

c. *Recall*

Dikenal juga sebagai True Positive Rate, didapat dari seluruh sampel positif yang diklasifikasikan benar sebagai positif oleh model.

$$\text{Recall} = \frac{TP}{TP+FN} \quad (2.3)$$

d. Spesifisitas (*Specifity)*

Metrik yang digunakan untuk mengevaluasi kinerja model klasifikasi, terutama dalam konteks klasifikasi biner. Spesifisitas mengukur proporsi dari kasus negatif yang benar-benar diidentifikasi dengan benar oleh model.

$$\text{Specifity} = \frac{TN}{TN+FP} \quad (2.4)$$

e. *F1-Score*

Merupakan kombinasi dari recall dan precision dalam satu pengukuran. Secara matematika, nilai ini merupakan rata-rata dari precision dan recall.

$$\text{F1 Score} = 2 \times \frac{Precision \times Recall}{Precision+Recall} \quad (2.5)$$

2.21 *MobileNetV2*

Keberhasilan metode deep learning dalam menyelesaikan berbagai permasalahan pada bidang visi komputer telah mendorong penerapannya secara luas. Salah satu contohnya adalah implementasi pada sistem pengenalan ekspresi wajah (*Face Expression Recognition*/FER) sebagaimana dijelaskan dalam penelitian. Dalam konteks ini, arsitektur *MobileNetV1* dan pengembangannya, *MobileNetV2*, menjadi solusi yang mampu secara signifikan mengurangi beban komputasi jika dibandingkan dengan metode deep learning lainnya, dengan hanya mengalami penurunan kinerja yang sangat kecil.

MobileNet termasuk ke dalam arsitektur *Convolutional Neural Network* (CNN) yang dirancang untuk mengatasi kebutuhan komputasi yang tinggi. Salah satu perbedaan utama antara *MobileNet* dan arsitektur CNN konvensional terletak pada jenis layer konvolusinya, di mana *MobileNet* menggunakan filter dengan ketebalan yang menyesuaikan dengan kedalaman (*channel*) dari citra masukan.

Proses konvolusi pada *MobileNet* dibagi menjadi dua tahap, yaitu *depthwise convolution* dan *pointwise convolution*. Depthwise convolution merupakan tahap awal yang menerapkan satu filter konvolusi untuk setiap *channel input* secara terpisah, sehingga menghasilkan pemrosesan yang lebih efisien. Selanjutnya, *pointwise convolution* menggunakan konvolusi 1×1 untuk menggabungkan hasil depthwise melalui kombinasi linier, membentuk fitur baru yang lebih *representative*, fitur yang lebih representatif adalah fitur yang telah diringkas dan dikombinasikan sedemikian rupa sehingga mampu menangkap esensi atau makna yang lebih kompleks dari data masukan (Zhang et al., 2021).

MobileNetV2 hadir sebagai penyempurnaan dari *MobileNetV1* dengan peningkatan kinerja pada berbagai tugas visi komputer dan berbagai ukuran model. Meskipun masih mengadopsi mekanisme *depthwise* dan *pointwise convolution*, *MobileNetV2* memperkenalkan dua inovasi utama, yaitu linear bottleneck dan *shortcut connection* antar *bottleneck*. Struktur *bottleneck* ini terdiri atas *input* dan *output*, sedangkan lapisan di dalamnya bertugas mentransformasikan *input* dari representasi tingkat rendah seperti piksel menjadi representasi tingkat tinggi seperti kelas atau kategori objek. Seperti halnya residual *connection* pada CNN tradisional, *shortcut* antar *bottleneck* berperan dalam mempercepat proses pelatihan dan meningkatkan akurasi model secara keseluruhan (Ibnul Rasidi et al., 2022).

2.22 *Flowchart*

Flowchart adalah Teknik analitis bergambar yang digunakan untuk menggambarkan beberapa aspek dari sistem informasi dengan cara yang jelas, ringkas, dan logis. Flowchart menggunakan seperangkat simbol standar untuk menggambarkan secara bergambar prosedur pemrosesan transaksi yang digunakan perusahaan dan aliran data melalui suatu sistem atau bagaimana dokumen mengalir pada suatu organisasi (Alwi, Gamaliel and Rondonuwu, 2023). Berikut daftar *flowchart* yang digunakan ada pada Tabel 2.5.

Tabel 2. 2 Penjelasan *Flowchart*

No	Simbol	Nama	Keterangan
1		*Terminator*	Simbol terminator menandai titik awal atau akhir dari sistem. Ini biasanya berisi kata 'Mulai' atau 'Akhir.'
2		*Process*	Sebuah kotak dapat mewakili satu langkah tunggal (‘tambahkan dua cangkir tepung’), atau keseluruhan sub-proses (‘buat roti’) dalam suatu proses yang lebih besar.
3		*Document Symbol*	Sebuah dokumen atau laporan yang dicetak.
4	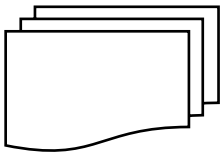	*Multidocument Symbol*	Mewakili beberapa dokumen dalam proses
5	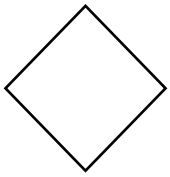	*Decision Symbol*	Sebuah keputusan atau titik percabangan. Garis-garis yang mewakili keputusan yang berbeda muncul dari titik-titik yang berbeda dari belah ketupat.
6	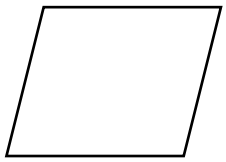	*Input/Output Symbol*	Mewakili bahan atau informasi yang masuk atau keluar dari sistem, seperti pesanan pelanggan (*input*) atau produk (*output*).

No	Simbol	Nama	Keterangan
7		*Subroutine Symbol*	Menunjukkan urutan tindakan yang melakukan tugas tertentu yang terbenam dalam proses yang lebih besar. Urutan tindakan ini dapat dijelaskan lebih rinci dalam flowchart terpisah

2.23 Tumbuhan

Tumbuhan merupakan organisme autotrofik yang memiliki kemampuan fotosintesis serta memainkan peran vital dalam ekosistem sebagai produsen primer. Menurut Rachmawati tahun 2022, tumbuhan adalah makhluk hidup dari kerajaan *Plantae* yang memilki dinding sel, klorofil, serta mampu melakukan fotosintesis sebagai ciri utama dalam memperoleh energi. Tumbuhan dibedakan menjadi berbagai kelompok berdasarkan morfologi, anatomi, dan perkembangan embrionya, salah satunya yaitu berdasarkan jumlah daun lembaga atau *kotiledon*. Pembagian utama dalam klasifikasi tumbuhan berbunga (*Angiospermae*) adalah Monokotil (*Monocotyledonae*) dan Dikotil (*Dicotyledonae*). Perbedaan mendasar antara kedua kelompok ini dapat diidentifikasi melalui ciri morfologis daunnya, terutama pada bentuk (*shape*) dan struktur tulang daun (*venation*). Daun monokotil umumnya memiliki bentuk yang memanjang, seperti pita dengan tulang daun yang sejajar, sementara daun dikotil cenderung lebih bervariasi bentuknya (misalnya menjari atau menyirip) dengan tulang daun yang bercabang atau menjala. Berikut perbedaan jenis tumbuhan Dikotil dan Monokotil pada Tabel 2.2.

Tabel 2. 3 Perbedaan Antara Tumbuhan Dikotil dan Monokotil
(Sumber: Ensiklopedi Anatomi Tumbuhan: Sifat-Sifat Batang serta Struktur dan Fungsi Jaringan batang)

No	Bagian Tumbuhan	Tumbuhan Berkeping Satu (Monokotil)	Tumbuhan Berkeping Dua (Dikotil)
1	Akar	Serabut	Tunggang

No	Bagian Tumbuhan	Tumbuhan Berkeping Satu (Monokotil)	Tumbuhan Berkeping Dua (Dikotil)
2	Batang	• Lurus tidak bercabang • Dari ujung sampai ke pangkal besarnya hampir sama • Ruas batang tampak jelas	• Bercabang • Semakin ke ujung semakin kecil • Ruas batang tidak begitu tampak
3	Daun	• Tunggal dan berpelepah • Tulang daun sejajar • Duduk daun berseling	• Ada yang tunggal, ada yang majemuk dan tidak berpelepah • Tulang daun menyirip atau menjari • Duduk daun tersebar atau berkarang
4	Bunga	Jumlah bagian bunga 3 atau kelipatannya	Jumlah bagian bunga umumnya 4,5 atau kelipatannya
5	Biji	Berkeping satu	Berkeping dua

2.23.1 Monokotil

Monokotil (*Monocotyledonae*) adalah tumbuhan yang memiliki satu *kotiledon* pada tahap embrionik. Dikutip dari Gramedia.com, tumbuhan monokotil memiliki sejumlah ciri khas yang membedakannya dari tumbuhan dikotil. Salah satu cirinya adalah memiliki biji yang berkeping tunggal. Pada bagian bunganya, tumbuhan monokotil umumnya memiliki kelopak, mahkota, dan benang sari yang jumlahnya tiga atau kelipatan tiga, seperti 3, 6, atau 9. Daunnya umumnya berurat sejajar atau melengkung serta memiliki pelepah daun, dan kebanyakan berupa daun

tunggal, kecuali pada beberapa jenis seperti tanaman palem. Batang monokotil mengandung pembuluh angkut atau berkas vaskuler bertipe kolateral tertutup, di mana xilem dan floem tidak dipisahkan oleh kambium. Ketiadaan kambium ini menyebabkan tidak terjadinya pertumbuhan sekunder, sehingga batang dan akar tumbuhan monokotil umumnya tidak mengalami pembesaran. Namun, ada pengecualian seperti pada tanaman sisa (*Agave sisalana*) yang memiliki kambium.

Susunan xilem dan floem pada batang monokotil tersebar dan tidak teratur. Selain itu, batang tumbuhan monokotil biasanya tidak bercabang, memiliki rambut-rambut halus, dan memperlihatkan ruas-ruas batang dengan jelas. Akar tumbuhan ini berbentuk serabut, dengan ujung akar yang dilindungi oleh koleoriza, sementara ujung batangnya dilindungi oleh koleoptil. Contoh dari tumbuhan monokotil, seperti padi (*Oryza sativa*), jagung (*Zea mays*), pisang (*Musa sp.*), kelapa (*Cocos nucifera*), tebu (*Saccharum officinarum*), bambu (*Bambusa sp.*), anggrek (*Orchidaceae*), jahe (*Zingiber officinale*), rumput (*Poaceae*), bawang merah (*Allium cepa*). Struktur anatomi batang monokotil tidak memungkinkan pembesaran diameter sekunder (Adelina Maria Mau and Berek, 2024). Berikut contoh tumbuhan monokotil ada pada Tabel 2.3.

Tabel 2. 4 Contoh Tumbuhan Monokotil

Nama Tumbuhan	**Gambar**
Padi (*Oryza sativa*)	
Jagung (*Zea mays*)	
Kelapa (*Cocos nucifera*)	

Nama Tumbuhan	Gambar
Tebu (*Saccharum officinarum*)	
Pisang (*Musa sp.*)	
Bambu (*Bambusa sp.*)	
Anggrek (*Orchidaceae*)	
Jahe (*Zingiber officinale*)	
Rumput (*Poaceae*)	

Nama Tumbuhan	Gambar
Bawang Merah (*Allium cepa*)	

2.23.2 Dikotil

Dikotil (*Dicotyledonae*) adalah tumbuhan yang memiliki *kotiledon* dalam tahap embrio serta menunjukkan morfologi dan anatomi yang berbeda dari monokotil. Menurut Theo tahun 2022 tumbuhan dikotil memiliki sistem akar tunggang, daun bertulang menyirip atau menjari, serta susunan pembuluh yang melingkar dan terdapat cambium yang memungkinkan pertumbuhan sekunder. Menurut Putri tahun 2021, kehadiran kambium ini memungkinkan tumbuhan dikotil untuk mengalami penebalan sekunder, suatu karakteristik penting dalam struktur berkayu. Dikutip dari Gramedia.com, Struktur akar pada tumbuhan dikotil, akar merupakan organ tumbuhan yang letaknya berada di dalam tanah dan memiliki fungsi menyerap air juga mineral dari tanah dan melekatkan ialah sebagai pondasi agar tumbuhan tubuh tegak dan juga kokoh, sehingga dapat tumbuh dengan maksimal. Akar tersebut berasal dari calon akar yang terdapat pada embrio.

Struktur luar akar tersebut terdiri dari batang akar, cabang akar, bulu akar serta tudung akar. Bagian paling ujung dari akar merupakan suatu titik tumbuh yang dilindungi oleh adanya tudung akar (*kaliptra*) yang dibentuk oleh *kaliptrogen*. Pada tumbuhan dikotil, batas pada ujung akar dengan kaliptra ini tidak jelas Sistem dari akar dikotil yang tunggang disebabkan oleh akar kecambahnya mengalami pertumbuhan secara terus menerus, bagian pangkal akar mempunyai ukuran yang lebih besar dari bagian ujung akar utama namun meskipun tunggang, akarnya tersebut tetap mempunyai cabang meskipun tidak serabut. Berikut contoh tumbuhan Dikotil pada Tabel 2.4.

Tabel 2. 5 Contoh Tumbuhan Dikotil

Nama Tumbuhan	**Gambar**
Mangga (*Mangifera indica*)	
Durian (*Durio zibethinus*)	
Jambu Biji (*Psidium guajava*)	
Singkong atau Ubi Kayu (*Manihot esculenta*)	
Kacang Tanah (*Arachis hypogaea*)	
Cabai (*Capsicum annuum*)	

Nama Tumbuhan	Gambar
Tomat (*Solanum lycopersicum*)	
Terung (*Solanum melongena*)	
Bunga Mawar (*Rosa sp.*)	
Pohon Jati (*Tectona grandis*)	

3. METODE PENELITIAN

3.1 Tahapan Penelitian

Penelitian ini melakukan klasifikasi 2(dua) jenis bentuk daun yaitu daun dikotil dan daun monokotil dengan menggunakan metode *Convolutional Neural Network* (*CNN*). Tahapan penelitian yang dilakukan dalam melakukan klasifikasi citra daun dikotil dan monokotil terdiri dari beberapa proses berikut.

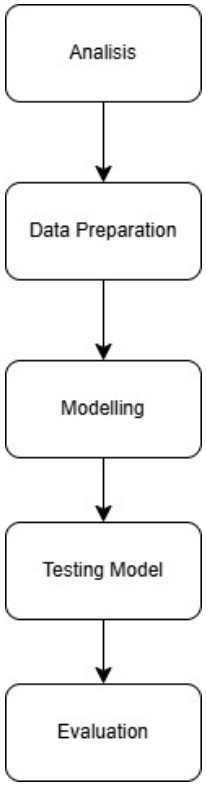

Gambar 3. 1 Tahapan Penelitian

Pada Gambar 3.1 merupakan proses dari tahapan penelitian yang akan dijelaskan sebagai berikut:

1. Analisis Tahap ini merupakan fase awal penelitian untuk mengidentifikasi seluruh komponen yang diperlukan agar penelitian berjalan efektif. Proses analisis mencakup beberapa hal.
    a. Identifikasi Masalah: Tahap ini dilakukan identifikasi permasalahan utama yang akan diteliti, seperti kesulitan dalam mengenali jenis

daun dikotil dan monokotil secara manual. Tahap ini juga mencakup penentuan tujuan, misalnya mengembangkan model klasifikasi untuk deteksi otomatis.

b. Analisis Kebutuhan: Menganalisis kebutuhan data, perangkat keras (*Hardware*), dan perangkat lunak (*Software*) yang akan digunakan. Kebutuhan ini mencakup spesifikasi laptop atau *smartphone*, serta *software* seperti Google Colaboratory dan Roboflow.

2. Data *Preparation*, Pada tahap yang bertujuan untuk mencari dan mengumpulkan data yang akan digunakan sebagai objek penelitian. Pada penelitian ini, data yang dikumpulkan berupa gambar daun dikotil dan monokotil, pada tahap ini berfokus pada proses pengolahan data gambar daun dikotil dan monokotil. Tahap ini mencakup beberapa proses seperti pembersihan data, augmentasi data, pelabelan data, pembagian data.
3. *Modeling*, Pada tahap impelentasi data yang telah dipersiapkan ke dalam model kecerdasan buatan yang telah ditetapkan. Pada penelitian ini, proses pemodelan menggunakan arsitektur *deep learning* yaitu *Convolutional Neural Network* (CNN).
4. *Testing Model*, Setelah model selesai dilatih, tahap selanjutnya adalah pengujian. Pada tahap ini, kemampuan model diukur menggunakan data uji (*testing set*), yaitu data yang belum pernah dilihat oleh model selama proses pelatihan maupun validasi. Tujuannya adalah untuk mengetahui seberapa baik model dapat melakukan generalisasi pada data baru.
5. *Evaluation*, Pada tahap akhir dilakukan dengan mengevaluasi model.

3.2 Analisis Kebutuhan

Analisis kebutuhan merupakan tahap awal dalam perancangan penelitian yang bertujuan untuk mengidentifikasi seluruh komponen yang diperlukan agar proses penelitian dapat berjalan secara efektif dan efisien. Komponen yang dianalisis meliputi kebutuhan perangkat lunak, perangkat keras, dan data yang mendukung proses pelatihan, evaluasi pada model klasifikasi penyakit daun dikotil dan monokotil.

3.1.1 Kebutuhan Perangkat Lunak

Tabel 3. 1 Kebutuhan Perangkat Lunak

No	Nama Perangkat Lunak	Keterangan
1	*Windows* 11	Sistem operasi yang digunakan untuk menjalankan seluruh proses penelitian
2	*Google Colaboratory*	Platform cloud untuk pemrograman Python dan pelatihan model CNN
3	Roboflow	Platform untuk eksplorasi dataset dan anotasi gambar
4	Microsoft Word	Digunakan untuk penyusunan laporan penelitian

3.1.2 Kebutuhan Perangkat Keras

Tabel 3. 2 Kebutuhan Perangkat Keras

No	Perangkat	Spesifikasi
1.	Laptop Acer Nitro 5 an515-57	• Intel® Core™ i5-11400H *processor* (12MB *cache*, up to 4.50Ghz) • *Random Access Memory* (RAM): 16 GB • Pengolah Grafis: NVIDIA® GeForce® RTX 3050 with 4GB of GDDR6 • Penyimpanan: SSD 1 TB dan HDD 1 TB
2	*Smarthphone* Poco X7 Pro	• Chipset: Mediatek Dimensity 8400 Ultra • *Random Access Memory* (RAM): 12 GB • Penyimpanan: 512 GB • Kamera: 50 MP, f/1.5, 26mm (*wide*), 1/1.95", 0.8µm, PDAF, OIS 8 MP, f/2.2, 15mm (*ultrawide*), 1/4.0", 1.12µm

3.1.3 Kebutuhan *Library*

Dalam penelitian ini, digunakan beberapa *library* Python yang mendukung proses analisis data, pelatihan model CNN, serta visualisasi data. Adapun *library* yang digunakan antara lain sebagai berikut:

Tabel 3. 3 Daftar *Library* Python yang digunakan

No	Nama *Library*	Fungsi
1.	Pandas	manipulasi dan analisis data dalam format tabular.
2.	Numpy	perhitungan numerik dan operasi array multidimensi.

No	Nama *Library*	Fungsi
3.	Matplotlib dan Seaborn	visualisasi data seperti grafik akurasi dan loss selama pelatihan model.
4.	TensorFlow dan Keras	membangun, melatih, dan menguji model CNN menggunakan arsitektur MobileNetV2.
5.	Roboflow	Mengunduh dan mempersiapkan dataset yang sudah diproses.

3.1.4 Kebutuhan Data

Data yang digunakan dalam penelitian ini diperoleh dari platform *web* Kaggle yang dibuat oleh irpaan.yy dan Mochammad Azriel Rizky Syahputra (2023 dan 2024), yang menyediakan kumpulan data gambar bentuk daun dikotil dan monokotil yang telah diklasifikasikan ke dalam dua kategori, yaitu dikotil dan monokotil. Kelas dikotil berjumlah 603 gambar dan kelas monokotil berjumlah 598, sehingga total dataset mencakup 1201 gambar.

3.3 Data *Preparation*

Setelah beberapa kumpulan data daun dikotil dan monokotil dikumpulkan. Selanjutnya kumpulan-kumpulan data tersebut akan dilakukan persiapan data. Persiapan data dilakukan guna untuk memproses kumpulan-kumpulan data agar bisa digunakan sebagai objek penelitian. Kumpulan-kumpulan data bersifat mentah, ukuran yang berbeda-beda dan belum terpisah untuk data *train*, valid dan *test*. Oleh karena itu dibutuhkan persiapan data agar kumpulan-kumpulan data yang akan diteliti bisa optimal. Tahap ini ada beberapa tahap-tahap lainnya agar kumpulan data menjadi objek yang solid. Diantaranya ada pembersihan data, augmentasi data, pemisahan data dan pelabelan data. Contoh *dataset* pada Gambar 3.2.

Gambar 3. 2 Gambar Daun Dikotil dan Daun Monokotil. Sumber: irpaan.yy dan Mochammad Azriel Rizky Syahputra.

3.3.1 Pembersihan Data

Pada tahap ini, dilakukan pembersihan terhadap data citra daun dikotil dan monokotil yang telah dikumpulkan. Tujuan dari proses ini adalah untuk memastikan bahwa data yang digunakan bebas dari kesalahan, duplikasi, dan ketidaksesuaian. Pembersihan menjadi penting karena pada dataset yang diperoleh terdapat beberapa citra dengan kualitas buram, tidak fokus, serta gambar yang tidak menampilkan objek daun dengan jelas.

Proses pembersihan data dilakukan secara manual dengan meninjau setiap citra satu per satu. Gambar yang terlihat buram, terlalu gelap, atau tidak fokus dihapus dari dataset. Selain itu, citra yang tidak menampilkan daun dikotil dan monokotil dengan jelas atau justru bukan objek daun juga dieliminasi agar tidak memengaruhi hasil pelatihan model. Seperti pada Gambar 3.3 citra daun yang buram.

Gambar 3. 3 Citra Daun yang tidak bagus (sumber: Penulis 2025).

3.3.2 *Preprocessing* dan Pelabelan Data

Pada tahap *preprocessing*, citra daun dikotil dan monokotil terlebih dahulu diproses menggunakan *platform* Roboflow untuk menyesuaikan dimensi dan orientasi gambar. Dua teknik preprocessing utama yang diterapkan adalah:

1. *Auto-orient*: Memperbaiki orientasi citra secara otomatis agar sesuai dengan posisi yang benar.
2. *Resize* (*Stretch to* 224x224): Menyesuaikan ukuran seluruh citra menjadi 224x224 piksel menggunakan metode *stretch to fill*, agar sesuai dengan dimensi input yang dibutuhkan oleh arsitektur model MobileNetV2 yang digunakan dalam penelitian ini.

Setelah dilakukan *preprocessing*, proses dilanjutkan ke tahap pelabelan data. Pelabelan data merupakan tahap penting dalam proses persiapan data karena secara langsung memengaruhi kualitas pelatihan model dan hasil evaluasi metrik. Pada penelitian ini, pelabelan dilakukan untuk mengklasifikasikan citra daun dikotil dan monokotil ke dalam beberapa kategori sesuai dengan kondisi atau jenis penyakit yang teridentifikasi. Proses pelabelan sangat krusial, terutama karena model yang digunakan bersifat pembelajaran terawasi *supervised learning*, yaitu *Convolutional Neural Network*, yang memerlukan data latih yang telah diberi label secara tepat.

Pelabelan data dilakukan menggunakan perangkat lunak *Roboflow*, yang mendukung anotasi citra secara efisien dan konsisten. Setiap citra diberi label berdasarkan dua kelas yang telah ditentukan sebelumnya, yaitu: Dikotil dan Monokotil.

Tampilan hasil pelabelan untuk masing-masing kategori dapat dilihat pada Gambar 3.4 dan 3.5, menunjukkan pelabelan pada daun dikotil dan monokotil.

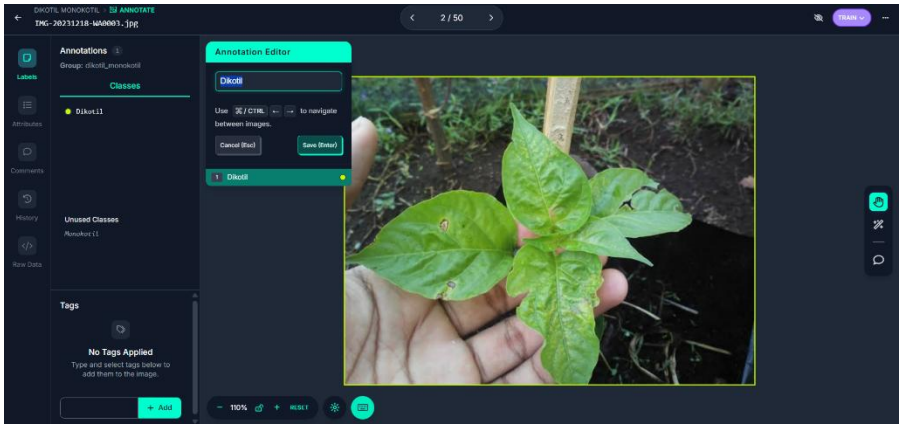

Gambar 3. 4 Proses Labelling Daun Dikotil (sumber: Roboflow).

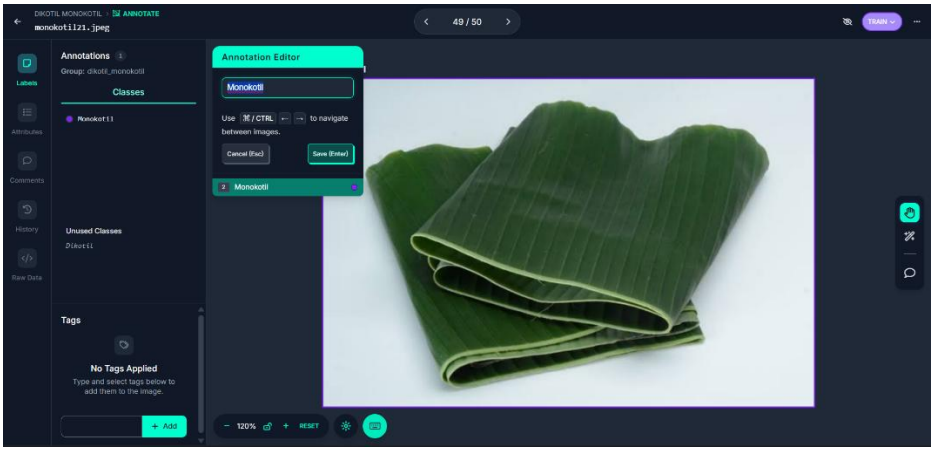

Gambar 3. 5 Proses Labelling Daun Monokotil (sumber: Roboflow).

Adapun distribusi jumlah data untuk masing-masing label yang telah ditetapkan ditunjukkan pada Gambar 3.6.

Gambar 3. 6 Jumlah pelabelan data (sumber: Roboflow).

3.3.3 Augmentasi Data

Augmentasi data merupakan proses penambahan jumlah data dengan tujuan memperbanyak kumpulan data sehingga meningkatkan kuantitas dan kualitasnya. Dengan bertambahnya data, model yang dilatih dapat mencapai tingkat akurasi dan evaluasi metrik yang lebih baik. Pada kondisi di mana data yang tersedia sangat terbatas, proses augmentasi menjadi sangat penting. Augmentasi data bukan berarti menambahkan data baru dari luar dataset, melainkan memperbanyak dan modifikasi data yang sudah ada agar kumpulan data menjadi meningkat.

Dalam penelitian ini, augmentasi data dilakukan menggunakan perangkat lunak Roboflow. Perangkat lunak ini mampu menggandakan data dengan menerapkan berbagai teknik augmentasi secara acak, sehingga menghasilkan kumpulan data yang lebih banyak dan berkualitas.

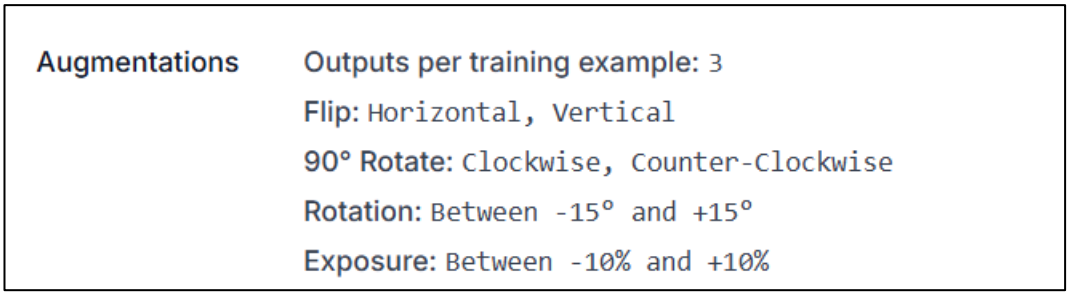

Gambar 3. 7 Proses augmentasi pada roboflow
(sumber: Roboflow).

Pada Gambar 3.7 ditampilkan beberapa proses augmentasi data yang tersedia di dalam Roboflow. Teknik-teknik ini juga umum digunakan pada proses augmentasi data. Teknik-teknik tersebut bekerja dengan menggandakan sebagian data yang sudah ada. Berikut adalah penjelasan dari masing-masing teknik augmentasi:

1. *Flip* adalah teknik yang menggandakan data lalu membalik arah data tersebut. Pembalikan ini dibagi menjadi dua jenis, yaitu membalik secara vertikal dan membalik secara horizontal.
2. 90° *Rotate* adalah teknik yang menggandakan data lalu memutarnya sebesar 90°. Rotasi ini dapat dilakukan searah jarum jam (*clockwise*), berlawanan arah jarum jam (*counter-clockwise*), atau diputar terbalik (*upside down*).

3. *Rotation* adalah teknik yang menggandakan data lalu memutar data tersebut. Rotasi dilakukan sebesar -15° (putar ke kiri 15 derajat) dan 15° (putar ke kanan 15 derajat).
4. *Exposure* adalah teknik yang menggandakan data lalu mengubah pencahayaan pada data tersebut. Perubahan pencahayaan dilakukan sebesar -10% (data dibuat sedikit lebih gelap) dan 10% (data dibuat sedikit lebih terang).

3.3.4 Pembagian Data

Pembagian data merupakan tahap penting dalam proses persiapan data yang bertujuan untuk memastikan bahwa model yang dikembangkan dapat dilatih, divalidasi, dan diuji secara optimal. Pada penelitian ini, data citra daun dikotil dan monokotil dibagi ke dalam tiga subset, yaitu data pelatihan (*training set*), data validasi (*validation set*), dan data pengujian (*testing set*). Adapun proporsi pembagian data dilakukan secara otomatis melalui platform *Roboflow* dengan rasio 80% untuk pelatihan, 10% untuk validasi, dan 10% untuk pengujian. Data pelatihan digunakan untuk melatih model *convolutional neural network* agar dapat mengenali pola dan karakteristik masing-masing jenis penyakit daun dikotil dan monokotil. Selanjutnya, data validasi berfungsi untuk menyesuaikan parameter model serta menghindari terjadinya *overfitting*, sehingga model tidak hanya menghafal data pelatihan tetapi juga mampu melakukan generalisasi terhadap data baru. Sementara itu, data pengujian digunakan untuk mengevaluasi performa akhir model dalam mengklasifikasikan citra yang belum pernah dilihat sebelumnya. Pemilihan rasio 80:10:10 didasarkan pada kajian literatur (Berlian Uly et al., 2023) yang menunjukkan bahwa pembagian dengan proporsi tersebut mampu menghasilkan model dengan kinerja klasifikasi yang baik dan stabil. Pembagian ini dilakukan secara merata untuk setiap kategori citra daun dikotil dan monokotil.

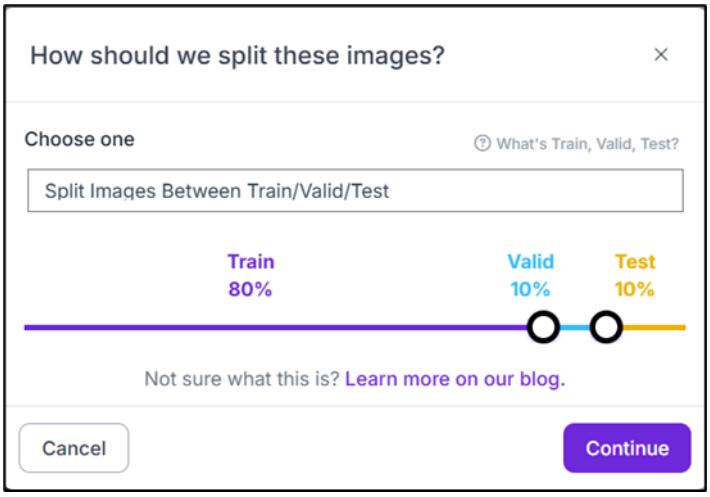

Gambar 3. 8 Pembagian Data Training, Validation, dan Testing di Roboflow (sumber: Roboflow).

3.4 Modeling

Tahapan *modeling* dalam penelitian ini merupakan proses membangun model klasifikasi citra untuk mendeteksi kondisi daun dikotil dan monokotil berdasarkan dataset yang telah dipersiapkan sebelumnya. Model dibentuk dengan menggunakan pendekatan deep learning melalui arsitektur *Convolutional Neural Network*. Proses ini dilakukan secara bertahap, dimulai dari perancangan arsitektur CNN yang sesuai dengan karakteristik data, kemudian dilanjutkan dengan proses pelatihan model menggunakan data latih yang telah diaugmentasi, dan diakhiri dengan pengujian untuk mengevaluasi kinerja model.

3.4.1 Arsitektur MobileNetV2

MobileNetV2 merupakan penyempurnaan dari MobileNetV1 yang masih mengadopsi mekanisme *depthwise separable convolution*, terdiri dari *depthwise convolution* yang memproses setiap saluran secara terpisah dan *pointwise convolution* (konvolusi 1×1) yang menggabungkan hasilnya. MobileNetV2 juga memperkenalkan dua inovasi utama, yaitu *linear bottleneck* dan *shortcut connection* antar *bottleneck*, yang meningkatkan efisiensi ekstraksi fitur dan membantu mempertahankan akurasi model tanpa menambah beban komputasi secara signifikan.

Penelitian sebelumnya yang dilakukan oleh (Hendri Butar-Butar and Marpaung, 2023)menunjukkan bahwa penggunaan MobileNetV2 untuk Identifikasi Daun Tanaman Obat menghasilkan performa akurasi yang tinggi. Model yang dilatih dengan 480 citra dan teknik fine-tuning pada lapisan tertentu mencapai akurasi hingga 97,66%, membuktikan bahwa MobileNetV2 sangat efektif dalam menyelesaikan masalah klasifikasi citra daun. Berdasarkan berbagai penelitian sebelumnya, arsitektur MobileNetV2 dipilih dalam penelitian ini karena efektif dalam menangani masalah klasifikasi citra dengan performa yang baik.

Dalam penelitian ini, penelitian ini membangun sebuah model untuk mengklasifikasikan citra daun dikotil dan monokotil. Model ini menggunakan citra berwarna dengan resolusi 224x224 piksel dan tiga channel warna (RGB) sebagai input. Arsitektur yang diterapkan adalah *transfer learning* dengan MobileNetV2 yang berfungsi sebagai *feature extractor*. Model MobileNetV2 sendiri terdiri dari serangkaian blok *depthwise convolution* dan *pointwise convolution* yang didukung oleh fungsi aktivasi ReLU6 untuk menangani nilai non-linear secara efisien.

Setelah fitur visual diekstraksi, hasilnya diratakan menggunakan *Global Average Pooling layer* 2D, yang lebih efektif dibandingkan *Flatten layer* dalam mengurangi risiko *overfitting*. Dilanjutkan dengan *Dropout layer* sebesar 0.2. Tahap akhir adalah *layer Dense* dengan 1 neuron dan fungsi aktivasi sigmoid yang dirancang khusus untuk tugas klasifikasi biner antara kelas "Dikotil" dan "Monokotil".

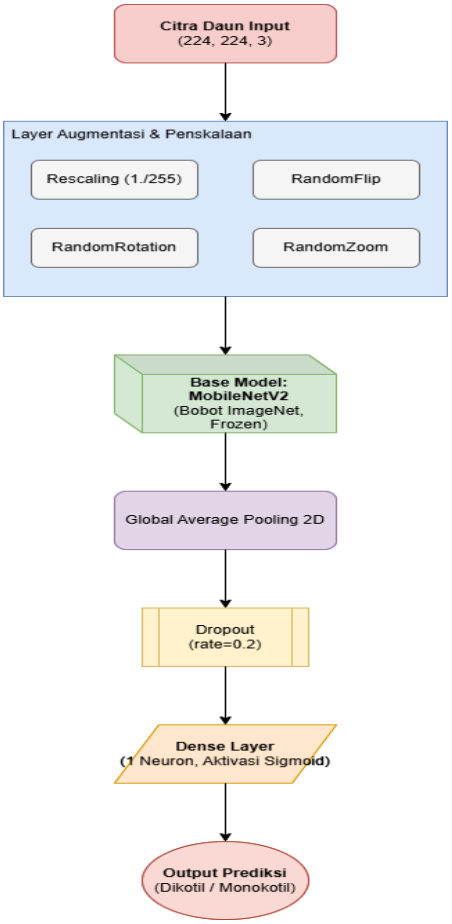

Gambar 3. 9 Diagram Arsitektur Model MobileNetV2.

3.4.2 Pelatihan Membentuk Model

Tahap pelatihan model bertujuan untuk membentuk model klasifikasi citra daun dikotil dan monokotil berdasarkan data yang telah dipersiapkan. Proses ini dilakukan setelah tahap persiapan data yang mencakup pelabelan, augmentasi, serta pembagian data menjadi tiga bagian menggunakan platform Roboflow, yaitu data latih sebesar 80%, data validasi sebesar 10%, dan data uji sebesar 10%. Dalam pelatihan ini, digunakan arsitektur MobileNetV2 sebagai model dasar dengan pendekatan *transfer learning*. MobileNetV2 dipilih karena memiliki bobot awal (*pre-trained*) yang sudah dilatih pada dataset ImageNet, sehingga mampu mengenali fitur-fitur visual umum. Lapisan akhir dari model dasar dihilangkan dan diganti dengan beberapa lapisan baru yang disesuaikan dengan kebutuhan klasifikasi dua kelas bentuk daun dikotil dan monokotil. Setelah proses ekstraksi

fitur dari MobileNetV2, model dilengkapi dengan lapisan *Global Average Pooling* yang meratakan fitur spasial tanpa menambah parameter, kemudian dilanjutkan dengan *Dropout Layer* sebesar 0.2 sebagai bentuk regularisasi untuk mengurangi risiko *overfitting*. Terakhir, ditambahkan *Dense Layer* dengan satu neuron dan fungsi aktivasi *softmax* yang menghasilkan *output* berupa probabilitas dari masing-masing kelas. Pelatihan model dilakukan dengan menggunakan TensorFlow dan Keras, dengan *loss function categorical_crossentropy, optimizer* Adam, dan metrik akurasi. Selama proses pelatihan, performa model dipantau berdasarkan data validasi untuk mengevaluasi kestabilan pembelajaran serta menghindari terjadinya *overfitting* atau *underfitting*.

3.4.3 Pengujian pada Model

Setelah pelatihan selesai, model dievaluasi menggunakan data uji yang tidak digunakan selama pelatihan maupun validasi. Tahap ini bertujuan untuk mengukur kemampuan model dalam mengklasifikasikan gambar baru yang belum pernah dilihat sebelumnya. Evaluasi dilakukan dengan metrik akurasi, presisi, *recall*, dan F1-score untuk masing-masing kelas bentuk daun dikotil dan monokotil. Hasil pengujian ini penting untuk menilai sejauh mana model dapat mengenali pola visual serta efektivitas arsitektur, proses augmentasi data, dan teknik regularisasi yang telah diterapkan selama pelatihan. Selain evaluasi kuantitatif menggunakan data uji, dilakukan juga pengujian fungsional dengan data tunggal (*single image*) untuk mensimulasikan penggunaan model dalam skenario dunia nyata.

3.5 Evaluation

Setelah proses pelatihan dan pengujian model dari kumpulan data, tahap selanjutnya adalah mencari nilai evaluasi metrik pada model tersebut. Hasil evaluasi yang digunakan adalah menggunakan pendekatan confusion matrix dengan menggunakan metode pengukuran hasil evaluasi berbasis label. Proses pertama perhitungan evaluasi yaitu menentukan nilai *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), *False Negative* (FN) yang telah di dapatkan,

perhitungan evaluasi dilanjutkan dengan menghitung *accuration, Precision, recall* dan *F1-score.* Seperti berikut:

Accuracy = $\frac{TP+TN}{TP+TN+FP+FN}$

Precision = $\frac{TP}{TP+FP}$

Recall = $\frac{TP}{TP+FN}$

F1-Score = $2\ x\ \frac{Precision\ x\ Recall}{Precision+Recall}$

4. HASIL DAN PEMBAHASAN

4.1 Hasil Persiapan Data

Penyelesaian masalah klasifikasi penyakit daun dikotil dan monokotil diawali dengan pemahaman terhadap karakteristik visual dari masing-masing bentuk daun. Dalam penelitian ini, citra bentuk daun diklasifikasikan ke dalam dua kategori, yaitu dikotil dan monokotil. Masing-masing kelas memiliki bentuk tulang daun yang berbeda. Untuk menyelesaikan permasalahan ini, digunakan metode *Convolutional Neural Network*.

4.1.1 Data Penelitian

Pada tahap ini dilakukan pencarian dataset citra daun dikotil dan monokotildari sumber terbuka. Dataset yang digunakan dalam penelitian ini diperoleh dari situs *Kaggle*, yang merupakan platform berbagi data dan proyek kecerdasan buatan. Di situs ini tersedia berbagai dataset yang dapat dimanfaatkan untuk klasifikasi citra dan tugas-tugas pengolahan data lainnya.

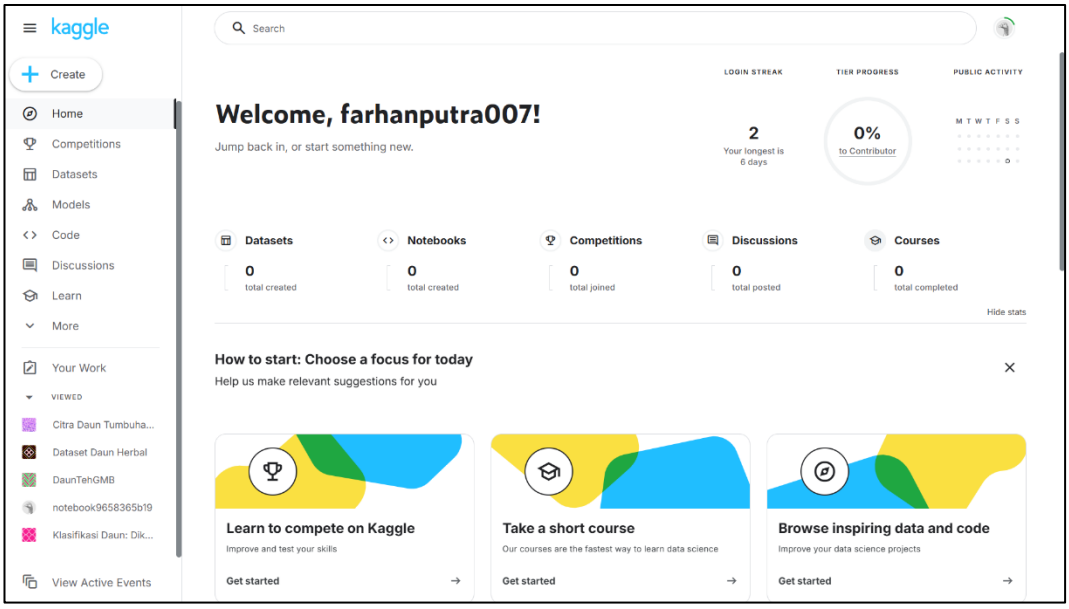

Gambar 4. 1 Tampilan *Website Kaggle*
(sumber: Kaggle 2025).

Pada Gambar 4.1 menampilkan halaman awal situs *Kaggle*. Untuk mencari *dataset* daun dikotil dan monokotil, pengguna dapat mengklik fitur *Search* dan mengetikkan kata kunci "dikotil dan monokotil" seperti terlihat pada Gambar 4.2.

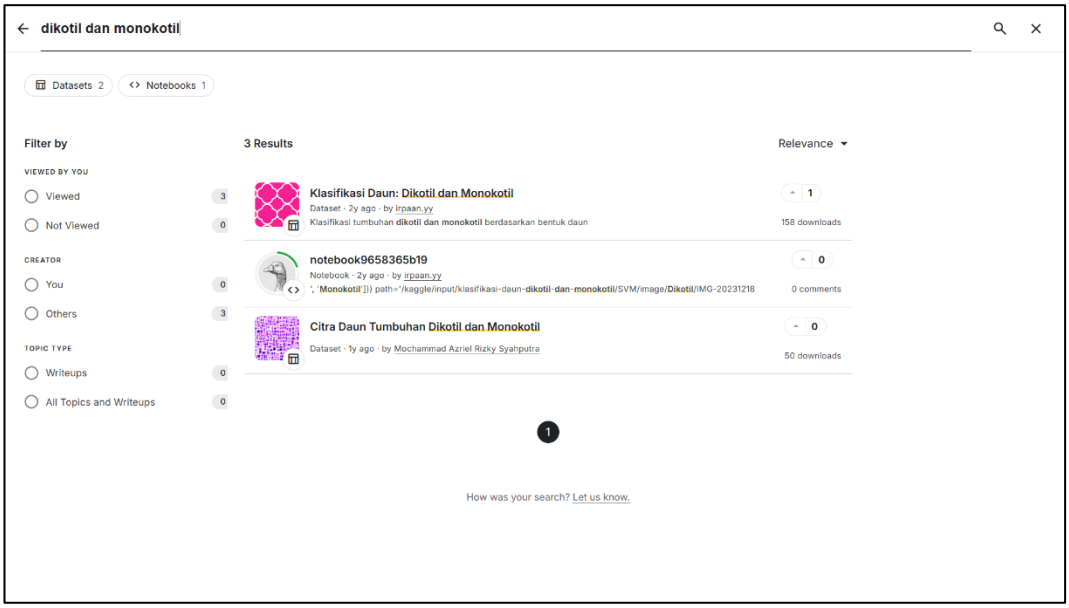

Gambar 4. 2 Pencarian bentuk daun dikotil dan monokotil
(sumber: Kaggle 2025).

Setelah hasil pencarian muncul, Gambar 4.2 menunjukkan salah satu *dataset* penyakit daun dikotil dan monokotil, yaitu " Klasifikasi Daun: Dikotil dan Monokotil " oleh Irpaan.yy dan Mochammad Azriel Rizky Syahputra. *Dataset* ini terdiri dari citra daun dikotil dan monokotil dalam berbagai bentuk daun.

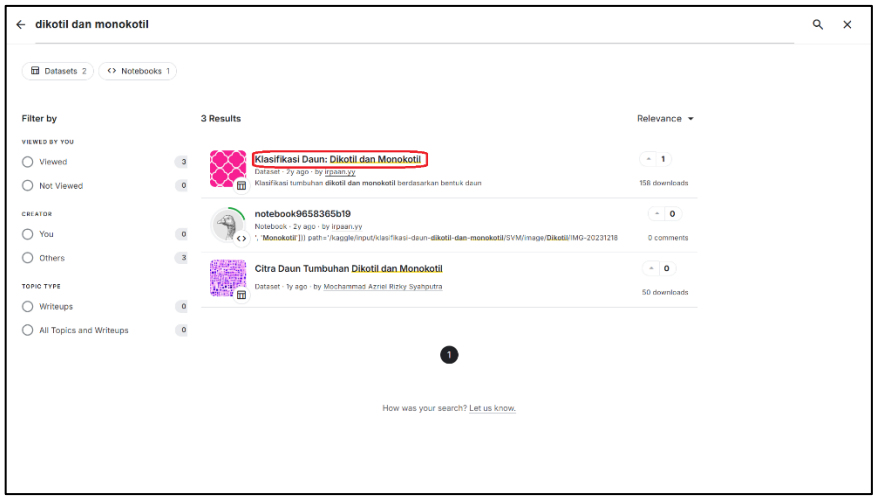

Gambar 4. 3 Hasil pencarian data daun dikotil dan monokotil (sumber: Kaggle 2025).

Pada Gambar 4.4, ditampilkan halaman detail *dataset* yang memuat informasi seperti jumlah data, klasifikasi kelas. File *dataset* tersedia dalam format *ZIP* dengan ukuran sekitar 5 MB dan dapat diunduh melalui tombol *Download*, lalu pilih "*Download dataset as zip* (5 MB)". Berikut tampilan Gambar 4.4.

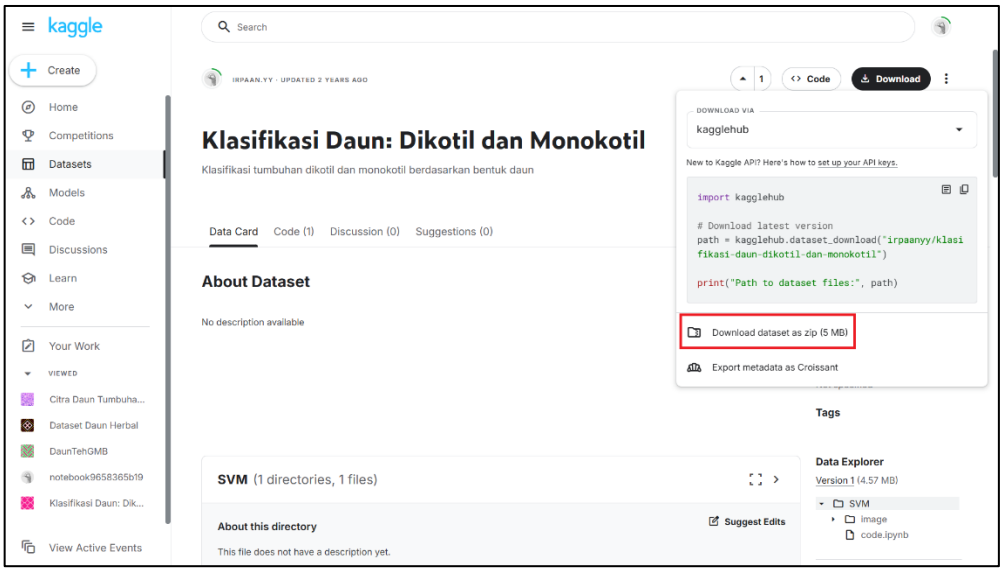

Gambar 4. 4 Tampilan Dataset daun dikotil dan monokotil
(sumber: Kaggle 2025).

4.1.2 Hasil Data Penelitian

Dataset berupa gambar bentuk daun dikotil dan monokoktil, yang sudah di ambil dan diunduh melalui *website Kaggle* dengan *username* Irpaan.yy dan Mochammad Azriel Rizky Syahputra. Contoh dari beberapa gambar daun dikotil dan monokotil yang sudah diunduh dapat dilihat pada Gambar 4.5 dan 4.6:

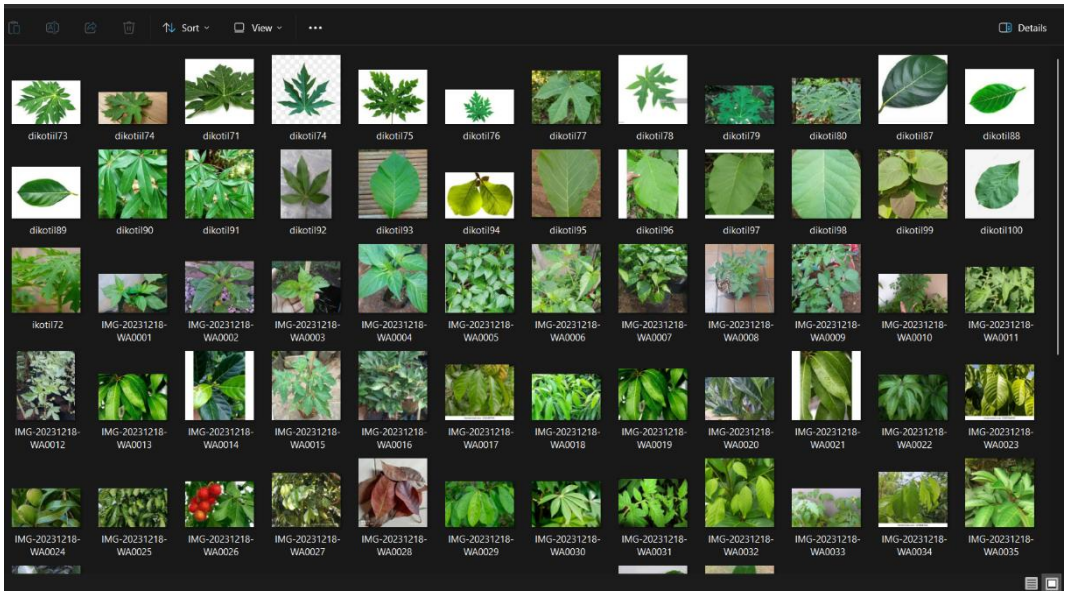

Gambar 4. 5 Tampilan gambar data daun dikotil.

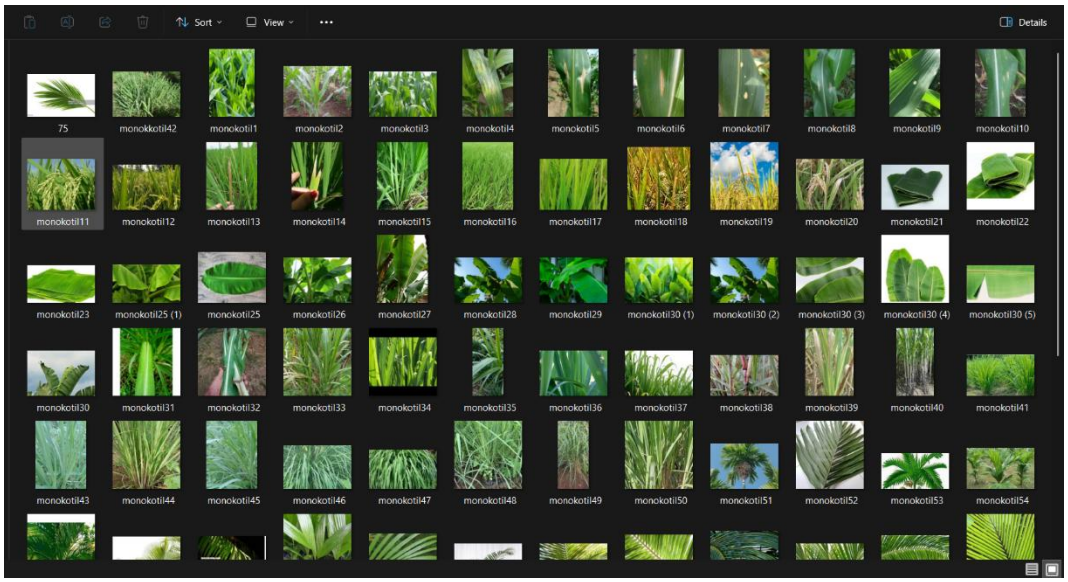

Gambar 4. 6 Tampilan gambar data daun monokotil.

4.2 Data Preparation

Dataset yang telah diunduh pada tahap sebelumnya dalam format *.zip* diekstrak ke dalam direktori lokal. Tahapan selanjutnya adalah melakukan proses data *preparation* guna mempersiapkan data sebelum dimasukkan ke dalam model pelatihan.

4.2.1 Pembersihan Data

Setelah proses ekstraksi, terdapat dua folder utama, yaitu Dikotil dan Monokotil. Langkah pertama dalam tahap ini adalah menyeleksi gambar-gambar yang memenuhi kualitas visual yang baik. Gambar yang tampak buram, tidak fokus, atau tidak menampilkan objek dari bentuk daun dengan jelas dikeluarkan dari *dataset*. Tujuan dari pembersihan ini adalah untuk memastikan model dilatih menggunakan data yang representatif dan berkualitas.

4.2.2 *Preprocessing* dan Pelabelan Data

Preprocessing dan pelabelan merupakan tahapan krusial dalam proses persiapan data karena secara langsung memengaruhi kualitas pelatihan model dan hasil evaluasi. Dalam penelitian ini, *preprocessing* dilakukan dengan menyesuaikan ukuran gambar menjadi 224x224 piksel menggunakan metode stretch to fill, agar kompatibel dengan arsitektur model MobileNetV2 yang digunakan. Proses ini dilakukan melalui fitur *preprocessing* yang disediakan oleh platform Roboflow.

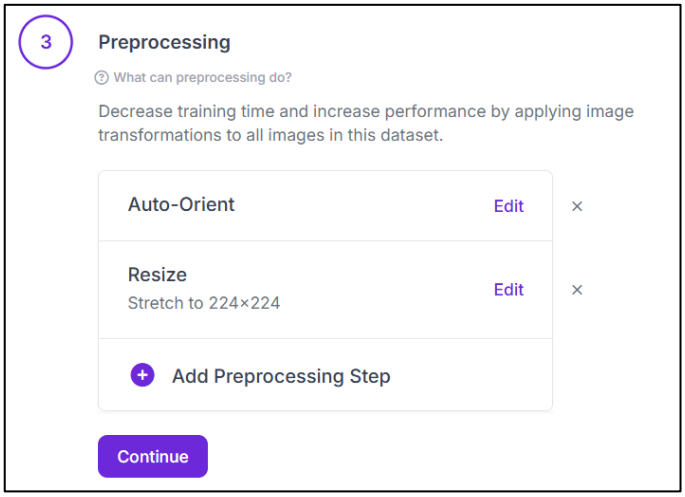

Gambar 4. 7 *Prepocessing* pada roboflow
(sumber: Roboflow).

Setelah tahap *preprocessing* selesai pada Gambar 4.7, proses dilanjutkan dengan pelabelan data. Proses pelabelan merupakan tahapan penting dalam persiapan data, karena secara langsung memengaruhi kualitas hasil pelatihan model. Pada penelitian ini, pelabelan dilakukan menggunakan *platform* Roboflow

yang mendukung anotasi gambar secara sistematis melalui fitur klasifikasi dan pengelompokan data berdasarkan label.

1. Langkah pertama dimulai dengan membuat proyek baru melalui tombol +New Project sesuai pada gambar 4.8.

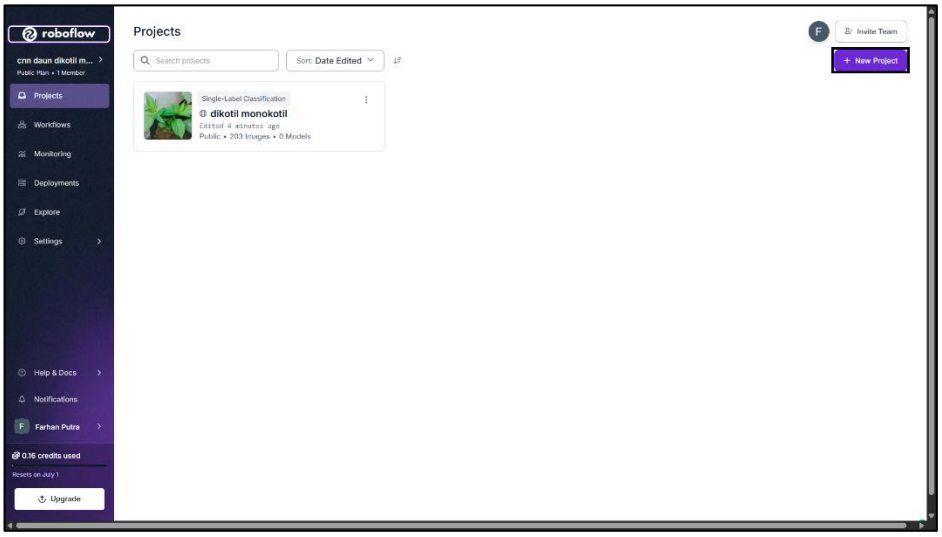

Gambar 4. 8 Tampilan awal roboflow (sumber: Roboflow).

2. Selanjutnya menentukan nama proyek, Kelompok anotasi, tipe proyek, dan lisensi. Pada penelitian ini akan menggunakan nama proyek “Daun Dikotil dan Monokotil” kelompok anotasi “Leaves_Dikotil_Monokotil”, tipe proyek “Classification – Single-class”. dan lisensi “MIT”. Pilihan ini akan dipaparkan pada Gambar 4.9.

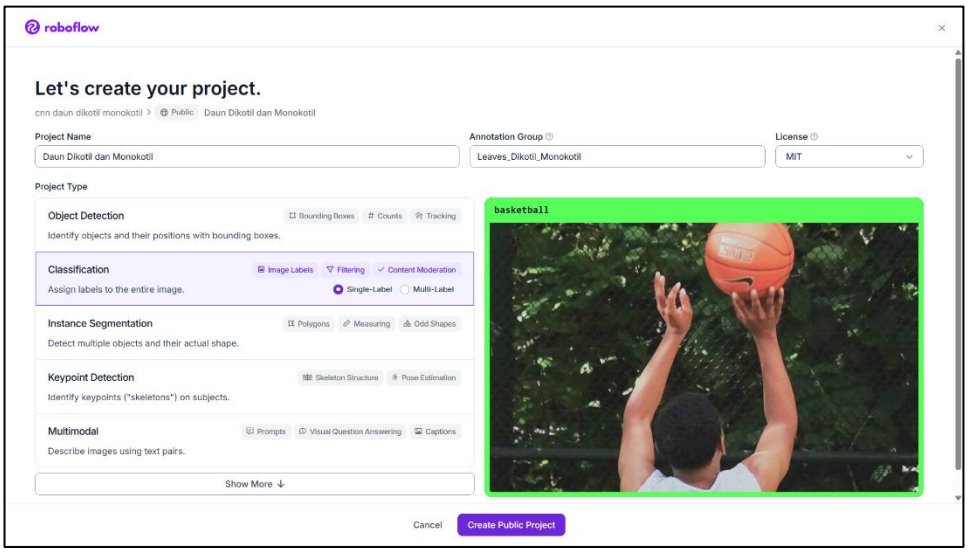

Gambar 4. 9 Tampilan untuk *create project* roboflow (sumber: Roboflow).

3. Setelah proyek berhasil dibuat, langkah selanjutnya adalah mengunggah folder utama berisi citra daun dikotil dan monokotil yang telah melalui tahap pembersihan. Folder yang diunggah merupakan folder "image", yang di dalamnya telah terbagi menjadi dua subfolder berdasarkan bentuk daun yaitu Dikotil dan monokotil. Tampilan untuk mengunggah file dapat dilihat pada Gambar 4.10.

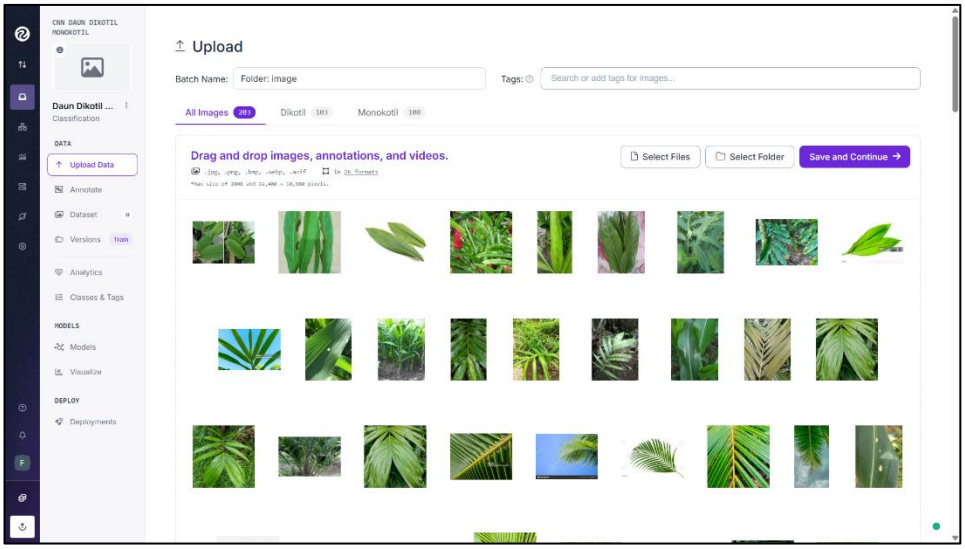

Gambar 4. 10 Isi folder "Image" pada roboflow (sumber: Roboflow).

4. Roboflow secara otomatis mengenali nama setiap subfolder sebagai label klasifikasi dan mengelompokkan citra ke dalam masing-masing kelas tersebut tanpa perlu melakukan pelabelan secara manual. Proses unggah ini dapat dilakukan dengan cara *drag and drop* folder ke area unggahan atau menggunakan tombol "Select Folder". Setelah proses unggah selesai, Roboflow akan menampilkan citra-citra yang telah teranotasi labelnya secara otomatis. Contoh tampilan gambar yang telah berhasil diklasifikasikan ditampilkan pada Gambar 4.11.

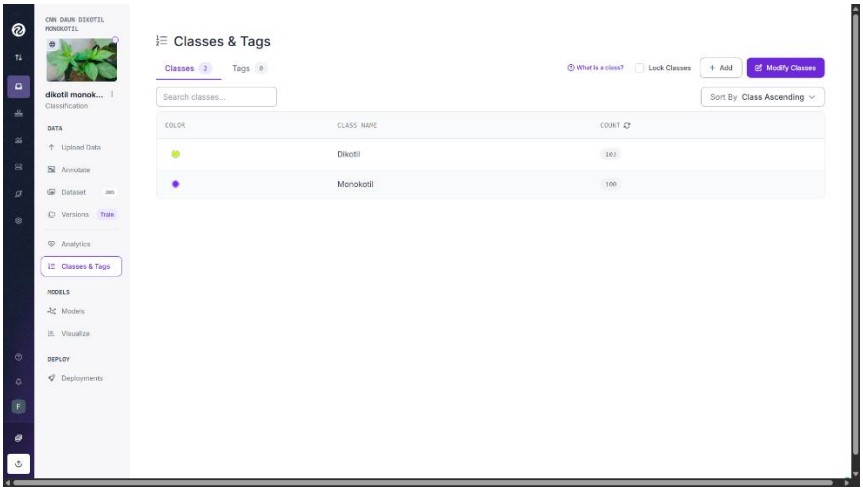

Gambar 4. 11 Tampilan citra daun telah berhasil diberi label (sumber: Roboflow).

4.2.3 Augementasi Data

Setelah seluruh citra berhasil diunggah dan diklasifikasikan, proses augmentasi dilakukan menggunakan fitur yang tersedia di Roboflow. Augmentasi diterapkan secara otomatis terhadap sebagian citra dengan berbagai teknik transformasi visual seperti rotasi, flipping, dan penyesuaian pencahayaan. Kombinasi teknik ini bertujuan untuk menambah keragaman data tanpa harus menambahkan citra baru dari luar. Hasil dari proses augmentasi dapat dilihat pada Gambar 4.12 yang menunjukkan variasi visual dari citra daun dikotil dan monokotil setelah dikenakan teknik augmentasi.

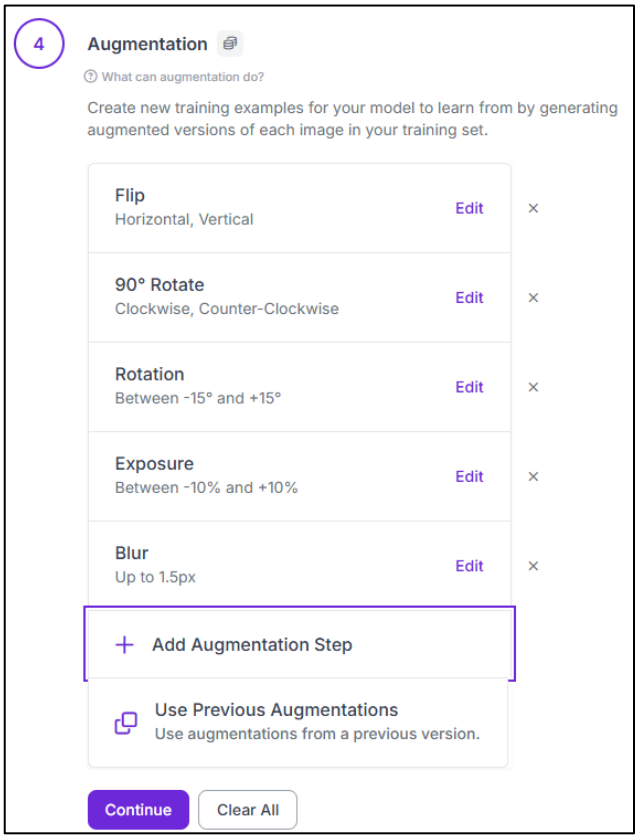

Gambar 4. 12 Proses Augmentasi pada roboflow (sumber: Roboflow).

4.2.4 Pembagian Data (*Split Data*)

Setelah augmentasi selesai, dataset dibagi menjadi tiga bagian menggunakan sistem pembagian otomatis Roboflow, yaitu 80% untuk pelatihan, 10% untuk validasi, dan 10% untuk pengujian. Proses pembagian ini dilakukan secara merata untuk setiap label, sehingga distribusi data tetap seimbang dan representatif di setiap subset. Gambar 4.13 menunjukkan antarmuka Roboflow yang memperlihatkan proporsi pembagian data tersebut, yang secara visual membantu memastikan bahwa tiap kelas telah terbagi dengan baik.

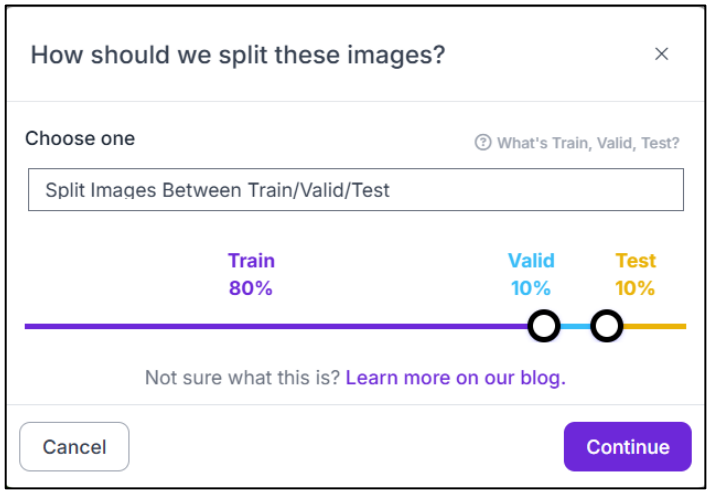

Gambar 4. 13 Proses *split dataset* pada roboflow (sumber: Roboflow 2025).

4.3 Arsitektur dan Pelatihan Model

Model klasifikasi dibangun menggunakan arsitektur MobileNetV2 dengan pendekatan *transfer learning*. Bobot dari model dasar MobileNetV2 yang telah dilatih pada dataset ImageNet dibekukan (*frozen*), dan lapisan klasifikasi atas diganti dengan lapisan baru yang sesuai untuk tugas klasifikasi biner ini: sebuah *Global Average Pooling 2D layer*, sebuah *Dropout layer* dengan *rate* 0.2, dan sebuah *Dense layer* sebagai output dengan 1 neuron dan fungsi aktivasi sigmoid. Model dikompilasi menggunakan *optimizer* Adam dengan learning rate 0.0001 dan *loss function binary_crossentropy*. Pelatihan dijalankan sebanyak 50 epoch dengan *batch size* 32.

4.4 Hasil Eksperimen dan Evaluasi Model

Pada tahap ini, model yang telah dilatih dievaluasi performanya menggunakan data latih, validasi, dan uji.

4.4.1 Hasil Pelatihan Model

Proses pelatihan model dipantau melalui grafik akurasi dan *loss* pada data latih dan data validasi, seperti yang ditampilkan pada Gambar 4.14.

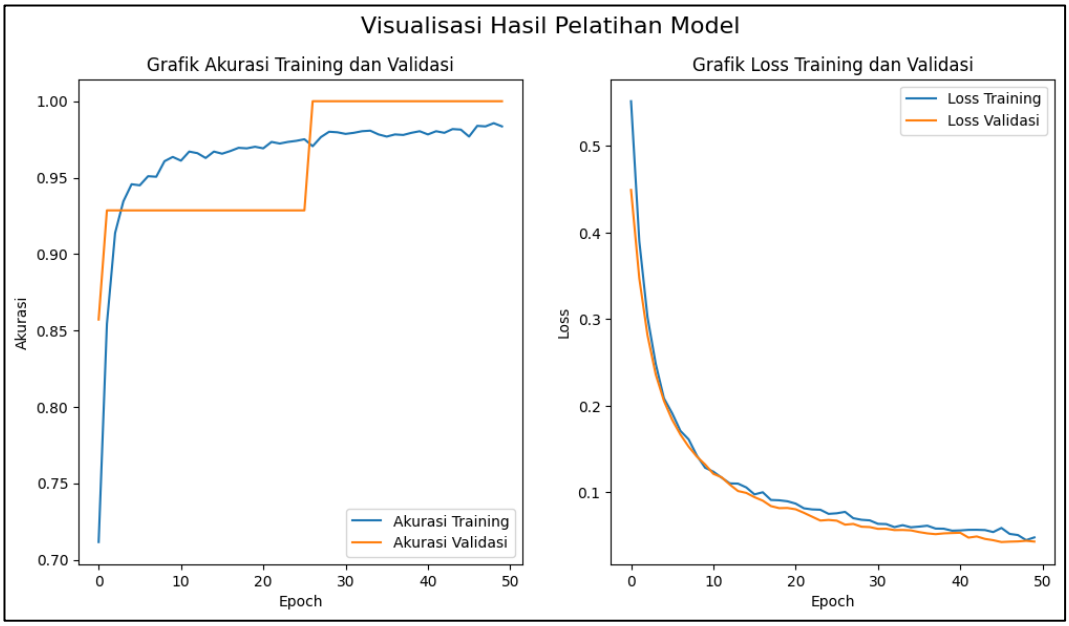

Gambar 4. 14 Grafik Akurasi dan *Loss* pelatihan dan validasi

Berdasarkan grafik di atas, kurva akurasi pelatihan (biru) dan validasi (oranye) sama-sama menunjukkan tren meningkat seiring berjalannya *epoch*. Sementara itu, kurva *loss* pelatihan dan validasi menunjukkan tren menurun. Pada *epoch* ke-50, model mencapai akurasi pelatihan sebesar 98.46% dan akurasi validasi sebesar 100.00%. Tidak terdapat celah yang signifikan antara kurva pelatihan dan validasi, yang menandakan bahwa model tidak mengalami *overfitting* dan mampu melakukan generalisasi dengan baik.

4.4.2 Hasil Evaluasi

Setelah proses pengujian menghasilkan prediksi, tahap selanjutnya adalah melakukan evaluasi terhadap performa model klasifikasi menggunakan metrik performa yang dihitung dari Confusion Matrix. Evaluasi ini bertujuan untuk mengukur seberapa baik model dalam mengklasifikasikan gambar daun mentimun berdasarkan lima kelas. Evaluasi dilakukan dengan menghitung nilai *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) untuk setiap kelas. Berdasarkan hasil pengujian terhadap 232 gambar uji, diperoleh data sebagai berikut.

Tabel 4. 1 Nilai TP, FN, FP, dan TN Per kelas

Kelas	**True Positif**	**False Negatif**	**False Positif**	**True Negatif**
Dikotil	117	3	1	115
Monokotil	115	1	3	117
Total	232	4	4	232

Berdasarkan Tabel 4.1, dapat dilihat bahwa model menunjukkan performa yang cukup baik dalam mengidentifikasi gambar dari setiap kelas. Nilai *True Positive* tertinggi diperoleh pada kelas Dikotil sebanyak 117 gambar, yang mengindikasikan bahwa sebagian besar gambar daun segar berhasil diklasifikasikan dengan benar. Di sisi lain, jumlah *False Negative* tertinggi terdapat pada kelas Dikotil, yaitu sebanyak 3 gambar. Hal ini mengindikasikan bahwa terdapat sejumlah citra pada kelas tersebut yang belum berhasil dikenali secara akurat oleh model sebagai bagian dari kelas yang sebenarnya.

Khusus untuk menghitung akurasi maka menghitung semua jumlah nilai TP dibagi dengan total keseluruhan prediksi. Sehingga hasil evaluasi dijabarkan sebagai berikut: rumus di besarkan

$$\text{Akurasi: } = \frac{Jumlah\ Prediksi\ yang\ Benar}{Jumlah\ Seluruh\ Prediksi} = \frac{117+115}{236} = 0{,}98$$

Tabel 4. 2 Perhitungan *Precision* Per Kelas

Kelas	**Rumus**	**Perhitungan**	**Hasil**
Dikotil	TP / (TP + FP)	117 / (117 + 1)	0.99
Monokotil	TP / (TP + FP)	115 / (115 + 3)	0.97

Nilai *precision* menunjukkan seberapa banyak prediksi positif yang benar dibandingkan seluruh prediksi positif. Hasil *precision* tertinggi tercapai pada kelas Dikotil yang masing-masing mencapai nilai hampir sempurna 0.99, artinya terdapat minim kesalahan dalam prediksi positif pada kedua kelas tersebut. Sementara itu, precision terendah terjadi pada Monokotil yaitu sebesar 0.97.

Tabel 4. 3 Perhitungan *Recall* Per Kelas

Kelas	**Rumus**	**Perhitungan**	**Hasil**
Dikotil	TP / (TP + FN)	117 / (117+ 3)	0.97
Monokotil	TP / (TP + FN)	115/ (115 + 1)	0.99

Recall mengukur seberapa baik model dalam mengidentifikasi semua data yang benar pada suatu kelas. Kelas Monokotil menunjukkan performa terbaik dengan nilai 0.99, menandakan hamper semua gambar pada kelas tersebut berhasil dikenali. Sebaliknya, nilai recall terendah terjadi pada kelas Dikotil, yaitu 0.97, yang menunjukkan adanya beberapa citra dari kelas tersebut yang belum dikenali secara tepat oleh model.

Tabel 4. 4 Perhitungan F1-*Score* Per Kelas.

Kelas	**Rumus**	**Perhitungan**	**Hasil**
Dikotil	2 * (P * R) / (P + R)	2 * (0.99 * 0.97) / (0.99 + 0.97)	0.98
Monokotil	2 * (P * R) / (P + R)	2 * (0.97 * 0.99) / (0.97 + 0.99)	0.98

F1-*Score* memberikan gambaran keseimbangan antara precision dan recall. Nilai tertinggi dicapai oleh kedua kelas yaitu Dikotil dan Monokotil. Hal ini menunjukkan bahwa klasifikasi untuk kelas tersebut relatif lebih menantang bagi model.

Untuk mendapatkan gambaran umum performa model secara menyeluruh, maka dihitung *macro average* untuk masing-masing metrik evaluasi:

Tabel 4. 5 Perhitungan *Macro Average*

Metrik	**Rumus**	**Perhitungan**	**Hasil**
MAP (Precision)	(∑ Precision per Kelas) / Jumlah Kelas	(0.99 + 0.97) / 2	0.98
MAR (Recall)	(∑ Recall per Kelas) / Jumlah Kelas	(0.97 + 0.99) / 2	0.98
MAF (F1-Score)	(∑ F1-Score per Kelas) / Jumlah Kelas	(0.98 + 0.98) / 2	0.98

Rata-rata makro memberikan nilai rata-rata dari setiap metrik tanpa mempertimbangkan jumlah data pada tiap kelas. Hasil *macro average precision*, *recall*, dan *F1-Score* menunjukkan konsistensi performa model antar kelas, dengan

nilai rata-rata yang berada di atas 0.90. Ini memperkuat hasil bahwa model memiliki performa klasifikasi yang merata dan baik pada masing-masing kelas.

4.4.3 *Confusion Matrix* dan Metrik Kinerja

Untuk menganalisis performa klasifikasi secara lebih rinci, dibuat *confusion matrix* seperti pada Gambar 4.15.

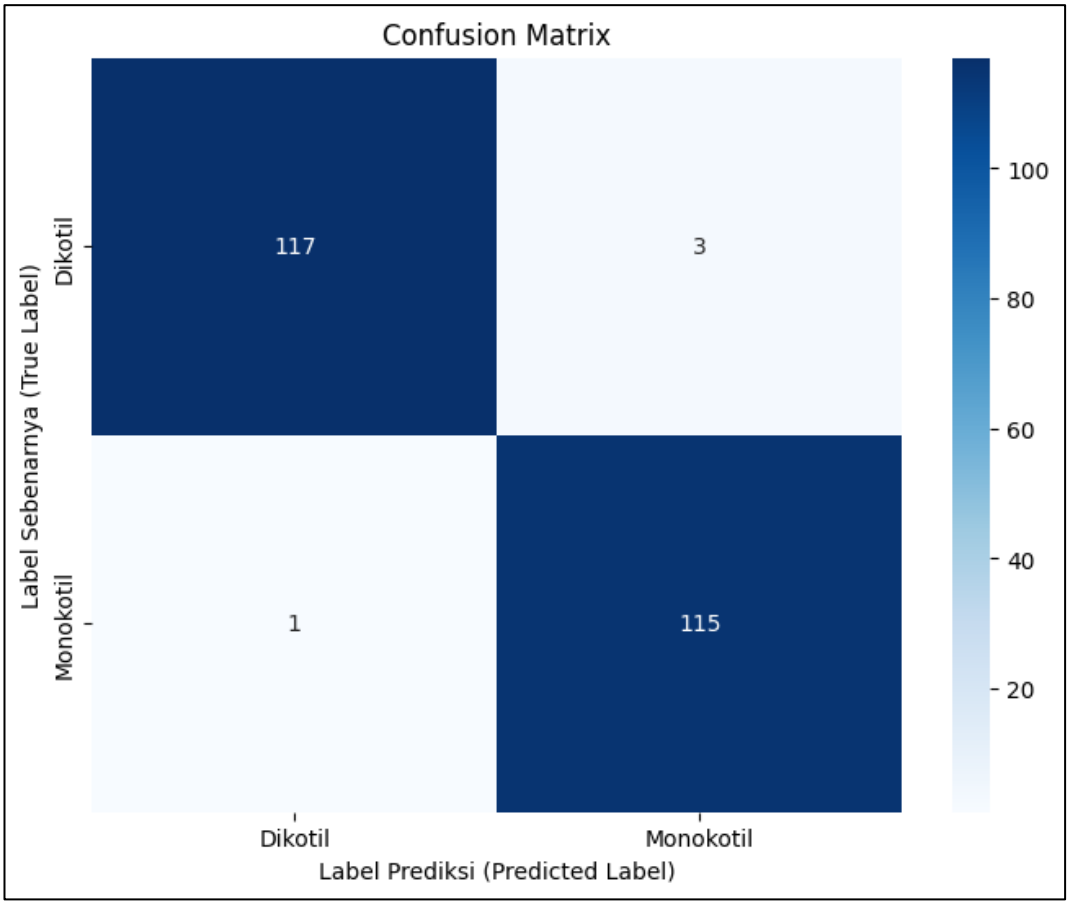

Gambar 4. 15 *Confusion Matrix* Hasil Pengujian Model.

Berdasarkan *confusion matrix* tersebut, dari 120 gambar dikotil, model berhasil memprediksi 117 dengan benar dan salah memprediksi 3. Sementara itu, dari 117 gambar monokotil, 115 diprediksi dengan benar dan hanya 1 yang salah diprediksi. Hal ini menghasilkan metrik kinerja yang sangat tinggi seperti yang ditunjukkan pada Tabel 4.6.

Tabel 4. 6 Laporan Klasifikasi Model

	Precision	**Recall**	**F1-score**	**support**
Dikotil	0.99	0.97	0.98	120
Monokotil	0.97	0.99	0.98	116
Accuracy			0.98	236
Macro avg	0.98	0.98	0.98	236
Weighted avg	0.98	0.98	0.98	236

Hasil penelitian menunjukkan bahwa model CNN dengan arsitektur *transfer learning* MobileNetV2 berhasil mengklasifikasikan citra daun dikotil dan monokotil dengan sangat baik. Keberhasilan ini dapat diatribusikan pada beberapa faktor. Pertama, arsitektur MobileNetV2 yang efisien mampu mengekstraksi fitur-fitur visual penting dari bentuk daun. Kedua, penerapan augmentasi data secara signifikan memperkaya variasi data latih, yang membuat model lebih tangguh dan mampu melakukan generalisasi dengan baik, yang didukung oleh grafik pelatihan (Gambar 4.14) di mana kurva validasi mengikuti kurva pelatihan dengan baik, menandakan tidak adanya *overfitting*.

4.5 Hasil Pengujian Data dan Akurasi

Setelah program pengujian berhasil dijalankan, selanjutnya mengukur keakuratan program dalam klasifikasi bentuk daun dan juga menguji program dalam berbagai kondisi data, seperti menguji beberapa gambar acak yang ada pada *dataset*, dan pengujian jenis bentuk daun.

Pengujian data untuk menilai akurasi menggunakan perbandingan 1:10 dari total 236 data *test* bentuk daun yang tersedia dalam data pengujian. Oleh karena itu, penulis memilih 23 data secara acak dari 236 data *test* yang ada dalam data pengujian. Hasil klasifikasi dapat dilihat pada Tabel 4.7.

Tabel 4. 7 Hasil Prediksi Label

No	Gambar	Jenis Bentuk Daun	Hasil Prediksi Label
1		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.49%
2		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 98.83%
3		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 88.60%
4		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 93.63%
5		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.13%
6		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 99.54%
7		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 98.24%

No	Gambar	Jenis Bentuk Daun	Hasil Prediksi Label
8		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.99%
9		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 94.10%
10		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.03%
11		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.96%
12		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 92.16%
13		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 98.30%

No	Gambar	Jenis Bentuk Daun	Hasil Prediksi Label
14		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 92.48%
15		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 99.90%
16		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 82.90%
17		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 99.84%
18		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.91%
19	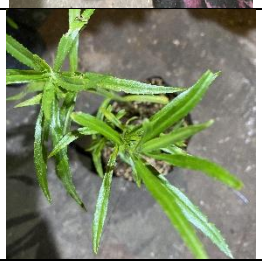	Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 96.26%

No	Gambar	Jenis Bentuk Daun	Hasil Prediksi Label
20		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.97%
21		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.93%
22		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.88%
23		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 99.83%

Berdasarkan Hasil dari pengujian 23 gambar acak, semua gambar terprediksi dengan benar. Jadi jumlah gambar yang berhasil diprediksi dengan benar, dengan presentase keyakinan diatas 70 persen adalah sebanyak 23 gambar bentuk daun dikotil dan monokotil. Selain pengujian menggunakan *data test* yang terstruktur, dilakukan pula pengujian fungsional untuk mengukur kemampuan model dalam mengklasifikasi data tunggal yang baru dan belum pernah dikenali sebelumnya. Pengujian ini mensimulasikan penggunaan model dalam skenario dunia nyata, di mana data yang masuk bisa jadi menyimpang (anomali) dari *dataset* yang digunakan saat pelatihan.

5. PENUTUP

5.1 Kesimpulan

Berdasarkan penelitian yang telah dilakukan, dapat disimpulkan bahwa penelitian telah berhasil merancang sebuah arsitektur *Convolutional Neural Network* (CNN) yang efektif untuk mengklasifikasikan tumbuhan dikotil dan monokotil berdasarkan bentuk daun. Arsitektur ini menerapkan metode *transfer learning* dengan menggunakan model dasar MobileNetV2 yang bobotnya dibekukan (*frozen*), dan menambahkan lapisan atas (*top layer*) yang terdiri dari lapisan augmentasi data, *Global Average Pooling 2D*, *Dropout* dengan *rate* 0.2, serta *Dense layer* sebagai keluaran dengan 1 neuron dan fungsi aktivasi sigmoid yang cocok untuk klasifikasi biner.

Evaluasi terhadap model yang telah dibangun menunjukkan performa yang sangat baik dan akurat. Berdasarkan pengujian pada 236 data uji, model berhasil mencapai akurasi sebesar 98,31%. Kinerja model yang seimbang juga dibuktikan dari laporan klasifikasi, dengan nilai *macro average* untuk *precision*, *recall*, dan *F1-score* yang masing-masing mencapai 0.98. Hasil ini menunjukkan bahwa model memiliki kemampuan generalisasi yang kuat pada data baru dan tidak mengalami *overfitting*.

Sistem yang dikembangkan berpotensi besar untuk memudahkan ahli botani dan masyarakat umum dalam mengklasifikasikan tanaman dikotil dan monokotil. Dengan tingkat akurasi yang tinggi (98,31%) dan kemampuan prediksi yang cepat pada gambar baru, model ini dapat menjadi alat bantu yang efisien untuk mengurangi waktu, tenaga, dan subjektivitas yang sering terjadi pada proses identifikasi manual.

5.2 Saran

Meskipun penelitian ini telah memberikan hasil yang signifikan, terdapat beberapa ruang untuk pengembangan di masa depan guna menyempurnakan dan memperluas manfaatnya. Untuk meningkatkan ketangguhan model, penelitian selanjutnya disarankan untuk memperkaya dataset dengan citra yang lebih beragam, mencakup berbagai kondisi pencahayaan, sudut pandang, serta latar

belakang yang lebih kompleks, dan juga membuat program sederhana dalam membersihkan data guna memberikan hasil yang lebih akurat. Seiring dengan penambahan data, cakupan klasifikasi dapat diperluas agar tidak hanya mengidentifikasi kategori dikotil dan monokotil, tetapi juga mampu mengenali spesies tanaman secara spesifik.

DAFTAR PUSTAKA

Adelina Maria Mau, T. and Berek, L.A.P., 2024. Pembelajaran Berbasis Lingkungan dalam Peningkatan Hasil Belajar Peserta Didik SMPK Don Bosco Atambua pada Materi Klasifikasi Tumbuhan Monokotil dan Dikotil. *JMA)*, 2(1), pp.3031–5220. https://doi.org/10.62281.

Alhamdani, A.A., 2022. Application of Deep Learning using Convolutional Neural Network (CNN) Algorithm for Gesture Recognition. *Journal of Software Engineering, Information and Communication Technology (SEICT)*, 4, pp.61–68. https://doi.org/10.17509/seict.v2i1.34673.

Alwi, A., Gamaliel, H. and Rondonuwu, S., 2023. Analisis Penerapan Sisetem Informasi Akuntansi Siklus Pendepatan Pada Cv Aneka Ritelindo Manado Pada Cv Aaneka Ritelndo Manado. *Jurnal EMBA*, 11(1), pp.281–291.

Amandri Achyar, A., Muhammud Olow, A., Rizky Perdana, M., Sundawijaya, A. and Dhiyaanisafa Goenawan, A., 2022. Identifikasi Ras Wajah dengan Menggunakan Metode Deep Learning Model Keras. *JURNAL TEKNIK MESIN, INDUSTRI, ELEKTRO DAN INFORMATIKA*, 1, pp.29–37. https://doi.org/10.55606/jtmei.v1i1.779.

Aras, S., Tanra, P. and Bazhar, M., 2024. Deteksi Tingkat Kematangan Buah Tomat Menggunakan YOLOv5. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, 4, pp.623–628. https://doi.org/10.57152/malcom.v4i2.1270.

Ardianto, R. and Wibisono, S.K., 2022. Application of Deep Learning using Convolutional Neural Network (CNN) Algorithm for Gesture Recognition. *Journal of Software Engineering, Information and Communication Technology (SEICT)*, 4, pp.61–68. https://doi.org/10.17509/seict.v2i1.34673.

Arifianto, J., Muhimmah, I. and July Arifianto, I.M., 2021. *Aplikasi Web Pendeteksi Jerawat Pada Wajah Menggunakan Algoritma Deep Learning dengan TensorFlow*. https://journal.uii.ac.id/AUTOMATA/article/view/19504.

Ashari, M.B.G.B., 2024. Implementasi Algoritma Convolutional Neural Network untuk Meningkatkan Identifikasi Penyakit Tanaman Durian. *Jupiter: Publikasi Ilmu Keteknikan Industri, Teknik Elektro dan Informatika*, 2(4), pp.162–172. https://doi.org/10.61132/jupiter.v2i4.418.

Baiju, B. V, Kirupanithi, N., Srinivasan, S., Kapoor, A. and Mathivanan, S.K., 2025. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. https://doi.org/doi.org/10.1186/s13007-025-01332-5.

Bakti, I. and Firdaus, M., 2023. Classification of Image Files of Lung X-Ray Results with Architecture Convolution Neural Network (CNN). *Journal of Information Technology*, 3, pp.26–34. https://doi.org/10.46229/jifotech.v3i1.590.

Berlian Uly, N., Iriani, A., Studi Magister Sistem Informasi Fakultas Teknologi Informasi Universitas Kristen Satya Wacana, P., Notohamidjojo No, J.O., Sidorejo, K., Salatiga, K. and Tengah, J., 2023. CNN-RNN Hybrid Model for Diagnosis of COVID-19 on X-Ray Imagery: Hybrid Model CNN-RNN untuk Diagnosis COVID-19 pada Citra X-Ray. *Digital Zone: Jurnal Teknologi Informasi dan Komunikasi*, [online] 14(1), pp.57–67. https://doi.org/10.31849/DIGITALZONE.V14I1.13668.

Darmawan, R. and Amini, S., 2022. *Perbandingan Hasil Sentimen Analysis Menggunakan Algoritma Naïve Bayes dan K-Nearest Neighbor pada Twitter Comparison of Sentiment Analysis Results Using Naïve Bayes and K-Nearest Neighbor Algorithm on Twitter*. [online] *Seminar Nasional Mahasiswa Fakultas Teknologi Informasi (SENAFTI) Jakarta-Indonesia*. Available at: <https://senafti.budiluhur.ac.id/index.php/>.

Fakhri, A. and Condro Winursito, Y., 2025. Analisis Penumpang Kapal Titanic Menggunakan Titanic Dataset dengan Bantuan Pemrograman Python. *Journal Sains Student Research*, 2. https://doi.org/10.61722/jssr.v2i1.759.

Farwati, M., Salsabila, I.T., Navira, K.R. and Sutabri, T., 2025. Analis Pengaruh Teknologi Artificial Intelligence (AI) Dalam Kehidupan Sehari-hari. *JURSIMA(Jurnal Sistem Informasi & Manajemen)*, 11. https://doi.org/10.47024/js.v11i1.563.

Gelar Guntara, R., 2023. Deteksi Atap Bangunan Berbasis Citra Udara Menggunakan Google Colab dan Algoritma Deep Learning YOLOv7. *Jurnal Manajemen Sistem Informasi (JMASIF)*, 2, pp.9–18. https://doi.org/10.59431/jmasif.v2i1.156.

Gilang Perwati, I., Suarna, N. and Suprapti, T., 2024. Analisis Klasifikasi Gambar Bunga Lily Menggunakan Metode Convolutional Neural Network (CNN) dalam Pengolahan Citra. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 8, pp.2908–2915. https://doi.org/10.36040/jati.v8i3.9193.

Hendri Butar-Butar, R.J. and Marpaung, N.L., 2023. Deep Learning untuk Identifikasi Daun Tanaman Obat Menggunakan Transfer Learning MobileNetV2. *Jurnal Informatika: Jurnal Pengembangan IT*, 8, pp.142–148. https://doi.org/10.30591/jpit.v8i2.5217.

Hidayat, M.A., Latifah Husni, N. and Damsi, F., 2022. Pendeteksi Banjir Dengan Image Processing Berbasis Convolutional Neural Network (CNN) pada Kamera

Pengawas. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, [online] 2(2), pp.10–18. https://doi.org/10.57152/MALCOM.V2I2.382.

Ibnul Rasidi, A., Pasaribu, Y.A.H., Ziqri, A. and Adhinata, F.D., 2022. Klasifikasi Sampah Organik dan Non-Organik Menggunakan Convolutional Neural Network. *Jurnal Teknik Informatika dan Sistem Informasi*, 8(1). https://doi.org/10.28932/JUTISI.V8I1.4314.

Ilham, I.R. and Utaminingrum, F., 2021. *Deteksi Helm untuk Keamanan Pengendara Sepeda Motor dengan Metode CNN (Convolutional Neural Network) menggunakan Raspberry Pi*. Jurnal Penghetahuan Teknologi Informasi dan Ilmu Komputer.

Jack Billie Chandra and Dewi Nasien, 2023. Application Of Machine Learning K-Nearest Neighbour Algorithm To Predict Diabetes. *International Journal of Electrical, Energy and Power System Engineering*, 6, pp.134–139. https://doi.org/10.31258/ijeepse.6.1.117-121.

Kurnia, R.P. and Atma, Y.A., 2022. Analisis Rekomendasi Film Menggunakan Data IMDb dengan Python. *DEVICE : JOURNAL OF INFORMATION SYSTEM, COMPUTER SCIENCE AND INFORMATION TECHNOLOGY*, 3, pp.23–28. https://doi.org/10.46576/device.v3i2.2698.

Lu, D., Wang, H., Chen, M., Lin, L., Car, R., E, W., Jia, W. and Zhang, L., 2021. 86 PFLOPS Deep Potential Molecular Dynamics simulation of 100 million atoms with ab initio accuracy. *Computer Physics Communications*, 259. https://doi.org/10.1016/j.cpc.2020.107624.

Mochamad Reza, D., Satria Mandala, Zaki, S.M. and Ming, E.S.L., 2023. Deep Learning Autoencoder Study on ECG Signals. *Jurnal Nasional Teknik Elektro*, 12, pp.82–88. https://doi.org/10.25077/jnte.v12n3.1117.2023.

Ningsih, P.T.S., Gusvarizon, M. and Hermawan, R., 2022. Analisis Sistem Pendeteksi Penipuan Transaksi Kartu Kredit dengan Algoritma Machine Learning. *Jurnal Teknologi Informatika dan Komputer*, 8(2), pp.386–401. https://doi.org/10.37012/jtik.v8i2.1306.

Pratiwi, H.A., Cahyanti, M. and Lamsani, M., 2021. Implementasi Deep Learning Flower Scanner Menggunakan Metode Convolutional Neural Network (CNN). *Sebatik*, 25, pp.124–130. https://doi.org/10.46984/sebatik.v25i1.1297.

Rahman, S., Sembiring, A., Siregar, D., khair, H., Prahmana, I.G., Puspadini, R. and Zen, M., 2023. *Python : Dasar Dan Pemrograman Berorientasi Objek*. https://tahtamedia.co.id/index.php/issj/article/view/344.

Ramadhani, Z., Safira, L., Hartanto, A.D. and Hartatik, H., 2022. Implementasi Algoritma SVM Dalam Pengembangan Sistem Presensi Berbasis Face

Recognition. *Intechno Journal (Information Technology Journal)*, 4, pp.42–47. https://doi.org/10.24076/intechnojournal.2022v4i2.1561.

Rochmawati, N., Hidayati, H.B., Yamasari, Y., Tjahyaningtijas, H.P.A., Yustanti, W. and Prihanto, A., 2021. Analisa Learning Rate dan Batch Size pada Klasifikasi Covid Menggunakan Deep Learning dengan Optimizer Adam. *Journal of Information Engineering and Educational Technology*, 5, pp.44–48. https://doi.org/10.26740/jieet.v5n2.p44-48.

Safitri, K. and Nasution, P., 2023. Analisis Penggunaan Aplikasi Google Drive Sebagai Media Penyimpanan Data. *JurnalJurnal Sains Dan Teknologi (JSIT)*, 3(3), pp.220–223. https://doi.org/http://jurnal.minartis.com/index.php/jsit.

Savitri, N.L.P.C., Rahman, R.A., Venyutzky, R. and Rakhmawati, N.A., 2021. Analisis Klasifikasi Sentimen Terhadap Sekolah Daring pada Twitter Menggunakan Supervised Machine Learning. *Jurnal Teknik Informatika dan Sistem Informasi*, 7. https://doi.org/10.28932/jutisi.v7i1.3216.

Sukma, F.D. and Mukhaiyar, R., 2022. Alat Pendeteksi Ekspresi Wajah Pada Pengendara Berbasis Image Processing. *JTEIN: Jurnal Teknik Elektro Indonesia*, [online] 3(2), pp.364–373. https://doi.org/10.24036/jtein.v3i2.261.

Trisiawan, I.K., Yuliza, Y. and Attamimi, S., 2022. Penerapan Multi-Label Image Classification Menggunakan Metode Convolutional Neural Network (CNN) Untuk Sortir Botol Minuman. *Jurnal Teknologi Elektro*, 13, p.48. https://doi.org/10.22441/jte.2022.v13i1.009.

Wartumi, W., Kurniawan, R. and Wijaya, Y.A., 2024. Analisis Data Sentimen Ulasan Pengguna Aplikasi Shopee di Google Play Store dengan Klasifikasi Algoritma NaÃ¯ve Bayes. *Jurnal Informatika dan Rekayasa Perangkat Lunak*, 6, pp.164–170. https://doi.org/10.36499/jinrpl.v6i1.10273.

Westenbroekf, T., Agrawalf, A., Castaneda, F., Sastry, S.S. and Sreenath, K., 2021. Combining Model-Based Design and Model-Free Policy Optimization to Learn Safe, Stabilizing Controllers. *IFAC-PapersOnLine*, [online] 54(5), pp.19–24. https://doi.org/10.1016/J.IFACOL.2021.08.468.

Yuniarossy, B.A., Hindrayani, K.M. and Damaliana, A.T., 2024. Analisis Sentimen terhadap Isu Feminisme di Twitter Menggunakan Model Convolutional Neural Network (CNN). *Jurnal Lebesgue : Jurnal Ilmiah Pendidikan Matematika, Matematika dan Statistika*, 5, pp.477–491. https://doi.org/10.46306/lb.v5i1.585.

Zhang, Q., Yang, Q., Zhang, X., Bao, Q., Su, J. and Liu, X., 2021. Waste image classification based on transfer learning and convolutional neural network. *Waste Management*, 135, pp.150–157. https://doi.org/10.1016/J.WASMAN.2021.08.038.

LAMPIRAN

Listing Program

Menginstall Library yang digunakan

```
!pip install roboflow -q
!pip install scikit-learn seaborn -q
```

```
import tensorflow as tf
from tensorflow.keras.models import Sequential, Model
from tensorflow.keras.layers import Dense, Dropout, GlobalAveragePooling2D,
Input
from tensorflow.keras.layers import Rescaling, RandomFlip, RandomRotation,
RandomZoom
from tensorflow.keras.applications import MobileNetV2
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.callbacks import EarlyStopping
from roboflow import Roboflow
import matplotlib.pyplot as plt
import numpy as np
from google.colab import files
from tensorflow.keras.utils import load_img, img_to_array
import seaborn as sns
from sklearn.metrics import classification_report, confusion_matrix
import os
import matplotlib.image as mpimg
```

Langkah 1: Mengunduh Dan Mempersiapkan *Dataset*

```
print("--- Mengunduh Dataset dari Roboflow ---")
# Autentikasi dengan Roboflow menggunakan API Key Anda
rf = Roboflow(api_key="gdc4xl0EiolM5OThCkoM")
project=rf.workspace("cnn-daun-dikotil-monokotil").project("dikotil-
monokotil")
version = project.version(5)
dataset = version.download("folder")

# Tentukan path ke direktori data
data_dir = dataset.location
train_dir = os.path.join(data_dir, 'train')
test_dir = os.path.join(data_dir, 'test')

print(f"Dataset telah diunduh dan berada di lokasi: {data_dir}")
print("-" * 30)
```

Langkah 2: Mempersiapkan Data Generator

```
print("--- Mempersiapkan Data Generator ---")
# Tentukan parameter untuk gambar dan batch
IMG_HEIGHT = 224
IMG_WIDTH = 224
BATCH_SIZE = 32

# Tentukan path ke direktori data
# Corrected paths assuming the structure is data_dir/train, data_dir/valid,
data_dir/test
train_dir = os.path.join(data_dir, 'train')
valid_dir = os.path.join(data_dir, 'valid')
test_dir = os.path.join(data_dir, 'test')

# Menggunakan image_dataset_from_directory untuk memuat data
# Ini adalah cara modern dan efisien di TensorFlow
train_dataset = tf.keras.utils.image_dataset_from_directory(
    train_dir,
    labels='inferred',
    label_mode='binary', # Karena hanya ada 2 kelas (dikotil/monokotil)
    image_size=(IMG_HEIGHT, IMG_WIDTH),
    interpolation='nearest',
    batch_size=BATCH_SIZE,
    shuffle=True
)

val_dataset = tf.keras.utils.image_dataset_from_directory(
    valid_dir,
    labels='inferred',
    label_mode='binary',
    image_size=(IMG_HEIGHT, IMG_WIDTH),
    interpolation='nearest',
    batch_size=BATCH_SIZE,
    shuffle=False
)

test_dataset = tf.keras.utils.image_dataset_from_directory(
    test_dir,
    labels='inferred',
    label_mode='binary',
    image_size=(IMG_HEIGHT, IMG_WIDTH),
    interpolation='nearest',
    batch_size=BATCH_SIZE,
    shuffle=False
)
```

```
# Dapatkan nama kelas dari dataset
class_names = train_dataset.class_names
print(f"Kelas yang ditemukan: {class_names}")
print("-" * 30)

# Optimalkan performa dataset dengan prefetching
AUTOTUNE = tf.data.AUTOTUNE
train_dataset = train_dataset.prefetch(buffer_size=AUTOTUNE)
val_dataset = val_dataset.prefetch(buffer_size=AUTOTUNE)
test_dataset = test_dataset.prefetch(buffer_size=AUTOTUNE)
```

Langkah 3: Membangun Arsitektur Model Dengan *Transfer Learning*

```
print("--- Membangun Model Transfer Learning dengan MobileNetV2 ---")

# 1. Definisikan layer untuk augmentasi data dan normalisasi
data_augmentation_rescaling = Sequential([
    Rescaling(1./255),
    RandomFlip("horizontal"),
    RandomRotation(0.2),
    RandomZoom(0.2),
], name="data_augmentation_rescaling")

# 2. Muat base model MobileNetV2 yang sudah terlatih di ImageNet
#    - include_top=False: hapus layer klasifikasi asli (1000 kelas)
#    - weights='imagenet': gunakan bobot yang sudah terlatih
base_model = MobileNetV2(input_shape=(IMG_HEIGHT, IMG_WIDTH, 3),
                         include_top=False,
                         weights='imagenet')

# 3. Bekukan bobot dari base_model agar tidak ikut terlatih
base_model.trainable = False

# 4. Buat arsitektur model baru di atas base_model
inputs = Input(shape=(IMG_HEIGHT, IMG_WIDTH, 3))
# Terapkan augmentasi dan rescaling
x = data_augmentation_rescaling(inputs)
# Jalankan base model dalam mode inference (penting karena ada layer
BatchNormalization)
x = base_model(x, training=False)
# Reduksi dimensi fitur yang dihasilkan base_model
x = GlobalAveragePooling2D()(x)
# Tambahkan dropout untuk regularisasi
x = Dropout(0.2)(x)
```

```
# Layer output baru untuk 2 kelas (Dikotil/Monokotil) dengan aktivasi sigmoid
outputs = Dense(1, activation='sigmoid')(x)

# Gabungkan menjadi model baru
model = Model(inputs, outputs)

print("--- Model Berhasil Dibangun ---")
print("-" * 30)
```

Langkah 4: Kompilasi Model

```
print("--- Melakukan Kompilasi Model ---")

# Gunakan learning rate yang sedikit lebih kecil untuk fine-tuning
opt = Adam(learning_rate=0.0001)

model.compile(
    optimizer=opt,
    loss='binary_crossentropy',
    metrics=['accuracy']
)

# Tampilkan ringkasan arsitektur model baru
# Perhatikan jumlah Trainable params yang jauh lebih sedikit!
model.summary()
print("-" * 30)
```

Langkah 5: Melatih Model

```
# Definisikan callback EarlyStopping untuk mencegah overfitting
# Pelatihan akan berhenti jika val_loss tidak membaik selama 5 epoch
# restore_best_weights=True akan mengembalikan bobot terbaik yang ditemukan
early_stopping = EarlyStopping(
    monitor='val_loss',
    patience=5,
    restore_best_weights=True
)

print("--- Memulai Pelatihan Model ---")
# Tingkatkan jumlah epoch, karena EarlyStopping akan menghentikannya jika sudah optimal
EPOCHS = 50
history = model.fit(
    train_dataset,
```

```
    validation_data=val_dataset,
    epochs=EPOCHS,
    callbacks=[early_stopping] # Gunakan callback
)
print("--- Pelatihan Selesai ---")
print("-" * 30)
```

Langkah 6: Visualisasi Hasil *Training* (Akurasi & Loss)

```
acc = history.history['accuracy']
val_acc = history.history['val_accuracy']
loss = history.history['loss']
val_loss = history.history['val_loss']

# Dapatkan jumlah epoch yang sebenarnya berjalan
actual_epochs = len(acc)
epochs_range = range(actual_epochs)

plt.figure(figsize=(12, 6))
plt.subplot(1, 2, 1)
plt.plot(epochs_range, acc, label='Akurasi Training')
plt.plot(epochs_range, val_acc, label='Akurasi Validasi')
plt.legend(loc='lower right')
plt.title('Grafik Akurasi Training dan Validasi')
plt.xlabel('Epoch')
plt.ylabel('Akurasi')

plt.subplot(1, 2, 2)
plt.plot(epochs_range, loss, label='Loss Training')
plt.plot(epochs_range, val_loss, label='Loss Validasi')
plt.legend(loc='upper right')
plt.title('Grafik Loss Training dan Validasi')
plt.xlabel('Epoch')
plt.ylabel('Loss')

plt.suptitle("Visualisasi Hasil Pelatihan Model", fontsize=16)
plt.show()
```

Langkah 7: Evaluasi Model Pada *Data Test*

```
print("--- Mengevaluasi Model pada Data Test ---")
test_loss, test_acc = model.evaluate(test_dataset, verbose=2)
print(f"\nAkurasi pada data test: {test_acc*100:.2f}%")
print(f"Loss pada data test: {test_loss:.4f}")
print("-" * 30)
```

Langkah 8: ***Confusion Matrix, Recall,*** **dan** ***F1-Score***

```
print("--- Menampilkan Laporan Klasifikasi dan Confusion Matrix ---")
# Dapatkan prediksi dari model
y_pred_probs = model.predict(test_dataset)
y_pred = (y_pred_probs > 0.5).astype(int).reshape(-1)

# Dapatkan label yang sebenarnya
y_true = np.concatenate([y for x, y in test_dataset], axis=0)

# 1. Confusion Matrix
cm = confusion_matrix(y_true, y_pred)
plt.figure(figsize=(8, 6))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
            xticklabels=class_names,
            yticklabels=class_names)
plt.title('Confusion Matrix')
plt.ylabel('Label Sebenarnya (True Label)')
plt.xlabel('Label Prediksi (Predicted Label)')
plt.show()

# 2. Laporan Klasifikasi (Recall, F1-Score, Precision)
print("\nLaporan Klasifikasi:")
print(classification_report(y_true, y_pred, target_names=class_names))
```

Langkah 9: Program Untuk Prediksi

```
def predict_and_display(image_path):
    """
    Fungsi untuk memprediksi gambar dan menampilkannya beserta hasilnya.
    """
    # 1. Menampilkan gambar yang diunggah
    img = mpimg.imread(image_path)
    plt.imshow(img)
    plt.axis('off') # Sembunyikan sumbu x dan y
    plt.show()

    # 2. Mempersiapkan gambar untuk model
    # Muat gambar dengan ukuran yang sesuai dengan input model
    img = load_img(image_path, target_size=(IMG_HEIGHT, IMG_WIDTH))
    # Ubah gambar menjadi array numpy
    img_array = img_to_array(img)
      # Tambahkan dimensi batch (model mengharapkan input berbentuk
(batch_size, height, width, channels))
```

```
    img_array = np.expand_dims(img_array, axis=0)

    # 3. Lakukan prediksi
    # Model Anda sudah termasuk layer Rescaling, jadi tidak perlu normalisasi
manual di sini
    prediction = model.predict(img_array)
    score = prediction[0][0] # Dapatkan nilai probabilitas dari output sigmoid

    # 4. Interpretasi hasil prediksi
    # Ingat: label_mode='binary' dan class_names diurutkan secara abjad.
    # Biasanya 'Dikotil' -> 0 dan 'Monokotil' -> 1
    # Jika score < 0.5, prediksi adalah kelas 0. Jika >= 0.5, prediksi adalah kelas
1.

    if score < 0.5:
        predicted_class = class_names[0] # Kelas dengan index 0 (Dikotil)
        confidence = (1 - score) * 100
    else:
        predicted_class = class_names[1] # Kelas dengan index 1 (Monokotil)
        confidence = score * 100

    print(f"Gambar ini diunggah ke: {image_path}")
    print(f"Hasil Prediksi: {predicted_class}")
    print(f"Tingkat Keyakinan: {confidence:.2f}%")

# --- MEMBUKA INTERFACE UPLOAD FILE ---
print("Silakan unggah gambar daun (format .jpg, .jpeg, atau .png)")
uploaded = files.upload()

# Loop melalui file yang diunggah dan lakukan prediksi
for fn in uploaded.keys():
  predict_and_display(fn)
```

Output Program

No	Gambar	Jenis Bentuk Daun	Hasil Prediksi Label
1		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.49%
2		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 98.83%
3		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 88.60%
4		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 93.63%
5		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.13%
6		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 99.54%
7		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 98.24%

No	Gambar	Jenis Bentuk Daun	Hasil Prediksi Label
8		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.99%
9		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 94.10%
10		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.03%
11		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.96%
12		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 92.16%
13		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 98.30%

No	Gambar	Jenis Bentuk Daun	Hasil Prediksi Label
14		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 92.48%
15		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 99.90%
16		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 82.90%
17		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 99.84%
18		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.91%
19	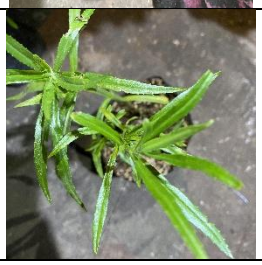	Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 96.26%

No	Gambar	Jenis Bentuk Daun	Hasil Prediksi Label
20		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.97%
21		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.93%
22		Monokotil	Hasil Prediksi: Monokotil Tingkat Keyakinan: 99.88%
23		Dikotil	Hasil Prediksi: Dikotil Tingkat Keyakinan: 99.83%